

学校代码：10251

学号：

華東理工大學

工程硕士学位论文

题 目

肿瘤细胞检测定位及跟踪算法研究与应用

专 业

电子信息

研究方向

计算机视觉，智能信息处理

姓 名

导 师

定稿时间： 年 月 日

学位论文使用授权声明

本学位论文作者完全了解学校有关保留、使用学位论文的规定，同意学校保留并向国家有关部门或机构送交论文的复印件和电子版，允许论文被查阅和借阅。本人授权华东理工大学可以将本学位论文的全部或部分内容编入有关数据库进行检索，可以采用影印、缩印或扫描等复制手段保存和汇编学位论文。保密论文在解密后遵守此规定。

论文涉密情况：

☐不保密

☐保密，保密期（ 年 月 日至 年 月 日）

学位论文作者签名：

指导老师签名：

日期： 年 月 日

日期： 年 月 日

分类号: _____ 密级: _____

U D C: _____

华东理工大学

工程硕士学位论文

肿瘤细胞检测定位及跟踪算法研究与应用

指导教师姓名: _____

申请学位级别: _____ 硕 士 _____ 工 程 领 域: _____ 电子信息 _____

论文定稿日期: _____ 论文答辩日期: _____

学位授予单位: _____ 华东理工大学 _____

学位授予日期: _____

作 者 声 明

我郑重声明：本人恪守学术道德，崇尚严谨学风。所呈交的学位论文，是本人在导师的指导下，独立进行研究工作所取得的结果。除文中明确注明和引用的内容外，本论文不包含任何他人已经发表或撰写过的内容。论文为本人亲自撰写，并对所写内容负责。

论文作者签名：

年 月 日

肿瘤细胞检测定位及跟踪算法研究与应用

摘要

细胞是所有生命形式的基本结构和功能单位。细胞的行为,包括形态变化和迁移运动,直接反映了其内部张力的动态变化。深入研究这些行为对理解组织发育、免疫反应以及伤口愈合等基本生物学过程具有重要意义。显微镜成像技术的发展极大地推动了生物医学研究,尤其是在细胞的空间-时间成像方面。通过观察细胞迁移活动,研究人员能够构建细胞谱系并分析其形态的变化。通过观察化学物质刺激下的细胞迁移与活性变化,能够为理解肿瘤疾病与异常细胞行为之间的关联性提供新的视角,有助于揭示相关致病因子的病理机制。

然而,由于显微图像的低信噪比、有限的时空分辨率及细胞形态、位置和运动轨迹的不稳定性,传统的多目标识别与跟踪算法难以精确检测跟踪细胞,不仅影响了细胞行为分析的准确性,还可能导致关键细胞行为的漏检,进而影响对疾病进程和病理状态的理解。

为了解决上述难点,本文首先设计基于轮廓注意力的渐进式细胞检测(Contour Attention-based Progressive Cell Detection, CAPCD)网络,用于定位检测细胞,并在此基础提出一种基于混合特征自适应匹配的 HFM-Tracker(Hybrid Features Matching based Tracker)细胞跟踪算法,跟踪细胞迁移运动。论文分析了不同浓度过氧化氢刺激下的 MCF-7 肿瘤细胞行为特征变化,探究过氧化氢刺激对细胞活性的影响。本文研究内容如下:

(1) 针对细胞轮廓模糊和背景难以区分的问题,设计了基于轮廓注意力的 CAPCD 网络。受活动轮廓模型的启发,将细胞检测任务视为轮廓回归问题。构建基于中心距离热力图编码的初始轮廓构建模型,用以获取细胞的初始目标框。设计了轮廓偏移预测网络来迭代回归细胞轮廓,引入轮廓注意力模块,使模型在轮廓变形过程中专注回归非细胞轮廓点。在模型训练阶段,提出基于轮廓点监督的偏移预测损失函数,以专注于细胞相邻的轮廓点,从而提高模型性能。实验结果表明,本文模型能有效提升对细胞轮廓的分割精度,在 MCF-7 肿瘤细胞数据集上 AP_{50} 达到了 87.3%。

(2) 针对在细胞跟踪过程中外观轮廓相似的细胞容易导致目标丢失的问题,提出一种基于混合特征自适应匹配的 HFM-Tracker 算法。在数据关联阶段,将细胞形态特征与混合运动特征加权整合到自适应代价矩阵(Adaptive Cost Matrix, ACM)中,以关联细胞运动轨迹,形态特征通过基于尺度不变的 Hu 不变矩进行提取,混合运动特征则结合 GIoU、欧氏距离和面积比进行度量。设计自适应特征匹配策略计算代价矩阵以获取比固定加权系数更为准确的细胞跟踪结果。在公共数据集和本文细胞数据集上,细胞漏检和误检情况明显减少,与最新目标跟踪算法相比各项评价指标均有所提升。

(3) 为了探究过氧化氢刺激对 MCF-7 肿瘤细胞活性的影响，基于细胞跟踪实验结果，综合分析了细胞的形态特征与迁移运动变化。随着过氧化氢浓度的增加，细胞的长径比、圆度以及 MD 均呈下降趋势。高浓度过氧化氢环境明显抑制了细胞的迁移活性，细胞活性逐渐减弱，最终导致细胞形态收缩及死亡。实验结果验证了过氧化氢对 MCF-7 肿瘤细胞的抑制效果，为肿瘤疾病的研究和诊断提供了重要依据。

关键词：多细胞跟踪；CAPCD；HFM-Tracker；自适应特征匹配；细胞活性分析

Research and Application of Tumour Cell Localisation Analysis and Tracking Algorithm

Abstract

The cell is the basic structural and functional unit of all life forms. The behaviour of cells, including morphological changes and migratory movements, directly reflects the dynamics of their internal tensions. In-depth study of these behaviours is important for understanding fundamental biological processes such as tissue development, immune responses, and wound healing. The development of microscopic imaging techniques has greatly advanced biomedical research, especially in the spatial-temporal imaging of cells. By observing cell migration activity, researchers are able to construct cell lineages and analyse changes in their morphology. By observing changes in cell migration and activity under the stimulation of chemicals, new perspectives can be provided to understand the correlation between tumour diseases and abnormal cell behaviour, which can help to reveal the pathological mechanisms of the relevant causative factors.

However, due to the low signal-to-noise ratio, limited spatial and temporal resolution of microscopic images and the instability of cell morphology, location and movement trajectories, traditional multi-target recognition and tracking algorithms are difficult to accurately detect tracked cells, which not only affects the accuracy of the analysis of cellular behaviours, but also may lead to the omission of key cellular behaviours, which may in turn affect the understanding of the disease process and pathological state.

In order to solve the above difficulties, this paper firstly designs Contour Attention-based Progressive Cell Detection (CAPCD) network for locating and detecting cells, and on the basis of which proposes a Hybrid Features Adaptive Matching based HFM-Tracker (Hybrid Features Matching based Tracker) cell tracking algorithm to track cell migration movement. The paper analyses the changes in behavioural characteristics of MCF-7 tumour cells under different concentrations of hydrogen peroxide stimulation, and explores the effect of hydrogen peroxide stimulation on cell activity. The research content of this paper is as follows:

(1) A contour-attention based CAPCD network is designed to address the problem of blurred cell contours and indistinguishable backgrounds. Inspired by the active contour model, the cell detection task is regarded as a contour regression problem. An initial contour construction model based on centre-distance heat map encoding is constructed for obtaining the initial target frame of cells. A contour offset prediction network is designed to iteratively regress the cell contour, and a contour attention module is introduced to make the model focus on regressing non-cellular contour points during contour deformation. In the model training stage, an offset prediction loss function based on contour point supervision is proposed to focus on cell-adjacent contour points to improve the model performance. Experimental results show that the model in this paper can effectively improve the segmentation accuracy of cell contours, and the AP50 reaches 87.3% on the MCF-7 tumour cells dataset.

(2) Aiming at the problem that cells with similar appearance contours easily lead to target loss during cell tracking, an HFM-Tracker algorithm based on hybrid feature adaptive matching is proposed. In the data association stage, the cell morphological features and hybrid motion features are weighted and integrated into the Adaptive Cost Matrix (ACM) to associate the cell motion trajectories, the morphological features are extracted by scale-invariant Hu invariant moments based on scale invariance, and the hybrid motion features are combined with GIoU, Euclidean distance and area ratio for the metrics. An adaptive feature matching strategy is designed to compute the cost matrix to obtain more accurate cell tracking results than fixed weighting coefficients. On the public dataset and the cellular dataset of this paper, the cell leakage and false detection are significantly reduced, and all the evaluation indexes are improved compared with the latest target tracking algorithms.

(3) In order to explore the effect of hydrogen peroxide stimulation on the activity of MCF-7 tumour cells, based on the results of the cell tracking experiments, the morphological characteristics and migratory movement changes of the cells were comprehensively analysed. With the increase of hydrogen peroxide concentration, the length-to-diameter ratio, roundness as well as MD of the cells showed a decreasing trend. The high concentration of hydrogen peroxide environment obviously inhibited the migratory activity of the cells, and the cell activity gradually weakened, which eventually led to the morphological contraction and death of the cells. The experimental results verified the inhibitory effect of hydrogen peroxide on MCF-7 tumour cells, which provides an important basis for the research and diagnosis of tumour diseases.

Keywords: multi cell tracking; CAPCD; HFM-Tracker; adaptive feature matching; cell activity analysis

目录

第 1 章 绪论	1
1.1 研究背景及意义	1
1.2 国内外研究现状	2
1.2.1 多目标跟踪研究现状	2
1.2.2 多细胞跟踪研究现状	3
1.3 本文研究内容及创新点	4
1.4 本文组织结构	5
第 2 章 多目标跟踪相关算法与数据集介绍	7
2.1 多目标跟踪算法概述	7
2.2 基于检测的跟踪算法	8
2.2.1 目标检测算法	8
2.2.2 数据关联算法	14
2.3 联合检测的跟踪算法	16
2.4 数据集介绍	18
2.5 本章小结	19
第 3 章 基于轮廓注意力的渐进式细胞检测网络设计	20
3.1 轮廓分析相关理论	20
3.1.1 传统 Snake 算法	20
3.1.2 扩张圆形卷积	21
3.2 基于轮廓注意力的 CAPCD 网络	23
3.3 基于中心距离热力图编码的初始轮廓构建模型	24
3.4 基于轮廓注意力的轮廓偏移预测网络	27
3.4.1 轮廓特征提取模块	27
3.4.2 尺度平移不变的轮廓归一化方法	28
3.4.3 轮廓注意力模块	29
3.4.4 水平集后处理	30
3.4.5 混合损失函数	30
3.5 实验设置与结果分析	31
3.5.1 实验设置	31
3.5.2 评价指标	31
3.5.3 实验结果分析	32
3.6 本章小结	37

第 4 章 基于混合特征自适应匹配的细胞跟踪算法.....	38
4.1 多目标跟踪算法.....	38
4.1.1 DeepSORT 算法.....	38
4.1.2 ByteTrack 算法.....	39
4.2 基于混合特征自适应匹配的细胞跟踪算法.....	40
4.2.1 混合运动特征.....	41
4.2.2 细胞形态特征.....	43
4.2.3 自适应特征匹配策略.....	46
4.3 实验结果分析.....	46
4.3.1 评价指标.....	46
4.3.2 结果分析.....	48
4.3 本章小结.....	52
第 5 章 细胞定位跟踪算法的应用.....	53
5.1 细胞形态特征分析.....	53
5.2 细胞迁移运动分析.....	54
5.3 化学物质刺激下的细胞活性分析.....	55
5.4 本章小结.....	59
第 6 章 总结与展望.....	60
6.1 课题研究总结.....	60
6.2 后续研究工作展望.....	61
参考文献.....	62
致谢.....	68
攻读硕士学位期间研究成果.....	69

第1章 绪论

1.1 研究背景及意义

细胞是所有生命形式的基本结构和功能单位，它们不仅构成了生命体的基础，而且在维持生物体的正常功能中扮演着重要的角色。从单细胞生物到复杂的多细胞生物，细胞以其多样性和功能的复杂性展示了生命的奇迹。在理解生命过程方面，细胞提供了一个独特的视角。细胞响应环境变化的行为，通过繁殖和修复维持种群，以及细胞的生命周期，包括其分裂、成熟和死亡的过程，为研究者提供了理解生命过程和疾病机制的重要参照。

细胞通过一系列复杂而精细的分子机制和信号传递路径来调控形态变化和运动迁移，这些过程包括细胞骨架的重组，细胞与细胞外基质的相互作用，以及细胞表面受体对外部信号的响应。细胞内部的微环境变化，如细胞内 pH 值的改变、离子浓度的变化以及能量代谢状态的调整，都能影响细胞的行为模式。此外，细胞迁移和形态变化还可能受到邻近细胞以及远处组织通过分泌因子（如生长因子、细胞因子和激素）发出信号的调控。

细胞行为，包括细胞的形态和迁移，直接反映了细胞内部张力的动态变化。深入研究这些行为对理解组织发育、免疫反应以及伤口愈合等基本生物学过程具有重要意义^[1]。异常的细胞迁移行为不仅干扰正常生物功能，还可能导致包括畸形病变^[2]、自身免疫性疾病^[3]以及癌症扩散^[4]在内的多种疾病。例如，肿瘤细胞在转移过程中的定向迁移被认为是导致癌症死亡的主要原因之一^[5]。在这一过程中，肿瘤细胞从原始肿瘤位置活动迁移，通过血液循环和淋巴系统迁移和传播，最终在身体的其他部位形成新的病变，导致细胞失巢凋亡，引发严重的器官功能衰竭。这些复杂的细胞变化过程与细胞运动和细胞形态变化密不可分^[6, 7]。

显微镜成像技术的发展极大地推进了生物医学研究的进展，特别是在空间-时间细胞成像方面。这一技术使研究人员能够深入了解细胞运动、细胞增殖^[8]、胚胎发育^[9]以及肿瘤生成^[10]等生物过程。通过对细胞迁移活动的观察，研究人员能够构建细胞谱系，并分析细胞形态的变化^[11, 12]，深入探究细胞生命周期的各个阶段。

因此持续跟踪细胞的集体迁移行为^[13-16]，特别是观察化学物质刺激下的肿瘤细胞迁移，为理解肿瘤疾病与异常细胞行为之间的关联性^[17]提供了新的视角，进而有助于了解相关致病因子的病理机制，对于识别异常细胞行为和理解肿瘤疾病的进展过程至关重要。通过观察细胞的运动轨迹和形态变化，研究人员能够深入分析细胞发育和分化过程中的各种因素，如细胞间的信号传递、化学诱导和生理变化等，定量分析细胞的动态特性。这些数据不仅有助于肿瘤疾病的研究和诊断，也对生物医学的基础研究具有重要意义。

随着光学技术和计算机科学的发展，大量高质量的细胞图像被广泛应用于生物医学研究，然而，通过显微成像技术分析细胞行为面临多种挑战，包括单个细胞的形态多样

性和动态变化——如图 1.1 所示的细胞伸展、收缩和分裂等，以及细胞在大视场中的快速迁移，这些因素显著增加了细胞跟踪的难度。此外，显微图像的低信噪比、有限的时空分辨率，以及细胞形态、位置和移动轨迹的不稳定性进一步增加了跟踪难度，使得传统的多细胞跟踪技术难以精确地定位和跟踪细胞。




图 1.1 常见的细胞变形类型：(a) 细胞伸长，(b) 细胞收缩，(c) 细胞分裂

Fig 1.1 Common types of cell deformation: (a) cell elongation, (b) cell contraction, (c) cell division

1.2 国内外研究现状

1.2.1 多目标跟踪研究现状

多目标跟踪技术迄今已有超过六十年的发展历史。在此期间，研究人员提出了多种适应不同背景环境的算法，包括集成航迹分裂、粒子滤波、卡尔曼滤波、概率数据关联和交互式多模型等。多目标跟踪旨在利用相应的传感器数据来确定目标的位置、轨迹和特性。在处理多目标跟踪问题时，研究者需要确定跟踪的目标数量、各目标的身份识别以及收集有关目标的速度和位置等关键信息。多目标跟踪包含以下技术难点：目标特征的相似性、传感器的漏检、目标运动状态的变化以及目标间的相互遮挡等。这些因素综合作用，增加了跟踪的复杂性和挑战性。

2016 年 Bewley 提出了 SORT(Simple Online and Realtime Tracking, SORT)算法^[18]，该算法结合了卡尔曼滤波和匈牙利算法，利用目标检测框的位置信息来估计运动轨迹。SORT 以其高速的处理能力获得认可，但因未整合物体的外观特征及其他数据关联方法，在处理目标的消失与重现问题时效果有限，通常需要依赖持续的目标检测来更新 ID。

为了解决 SORT 中存在的限制，Wojke 于 2017 年提出了 DeepSORT 算法^[19]。DeepSORT 在 SORT 的基础上增加了一个深度学习模型来评估目标的外观信息，从而提高了对目标特征的识别能力。此外，DeepSORT 通过使用更复杂的数据关联策略，如马氏距离计算和非极大抑制(Non-maximum Suppression, NMS)处理^[20]，改善了对目标消失后再次出现的处理，从而增强了跟踪的稳定性和准确性。

ByteTrack 算法^[21]在 DeepSORT 算法的基础上改进了数据关联，通过高效的数据关

联,显著提升了在目标遮挡或间断出现的场景中的跟踪连续性。StrongSORT 算法^[22]则是改进了外观特征提取器,它使用深度学习技术来提取目标的视觉特征,另外改进了成本矩阵,更好地利用了外观特征和运动信息。

多目标跟踪领域通常将检测与跟踪作为两个独立的处理阶段进行。这种分阶段的处理方式虽然在逻辑上清晰,但往往导致算法结构复杂,各模块之间的耦合度低。

JDE 算法^[23]代表了一种多目标跟踪学习方法,通过一个统一的网络模型同时处理目标检测和外观特征的提取任务。JDE 算法基于 MOTMD 网络^[24]进行了改进,并设计为两个阶段的处理流程:首先在第一阶段输出目标检测框,然后再第二阶段通过嵌入学习模型实现跟踪。这种优化的整合检测与跟踪流程不仅提升了处理速度,也达到了较高的跟踪准确性。

FairMOT 算法^[25]在 JDE 算法的基础上改进,与 JDE 的主要区别在于,FairMOT 采用了无锚框(Anchor-free)的目标检测网络,并引入了多层特征聚合技术来解决尺度变化的问题,提升了算法在不同大小目标检测的敏感度和准确性。CenterTrack 算法^[26]则是基于 CenterNet^[27]的进一步改进,它将多目标跟踪问题转化为目标中心点的检测和跟踪问题。基于 CenterNet 检测目标中心点的核心思想,CenterTrack 通过定位每个目标的中心点,并预测这些中心点在连续视频帧之间的位移,从而有效链接目标的运动轨迹。

1.2.2 多细胞跟踪研究现状

在多细胞跟踪研究领域,由于显微图像通常为灰度图,缺乏丰富的颜色信息,同时细胞形态的相似性和动态状态也进一步复杂化了跟踪过程。跟踪需记录细胞在活动状态下的位置变化。细胞跟踪与细胞分割是两种不同的技术:分割是识别单个图像中的细胞,而跟踪则是分析连续帧图像,寻找图像帧之间的联系。在这一过程中,细胞的不规则移动和连续图像处理中的信息丢失问题都可能使跟踪更加困难。现有的细胞跟踪方法主要分为两类:基于模型进化的跟踪方法和基于检测的跟踪方法。

在基于模型进化的跟踪方法中,每个细胞图像视频帧的分割和跟踪是同时处理的。这类方法通常基于特征空间的数据,并假设曲线具有一定的平滑性。通过使用参数化或非参数化模型来描述细胞特征,并迭代这些模型的参数以预测细胞在下一帧的位置,从而为细胞间的连接提供依据,构建细胞的运动轨迹。在这种框架下,细胞可以通过参数化的或隐式的活动轮廓模型来表示。

参数化模型如高斯混合模型(Gaussian Mixture Model, GMM)^[28]、活动网格^[29]或活动轮廓^[13]都通过显式地表达细胞边界。GMM 模型通过统计学的方式在图像中识别和区分各个细胞。GMM 模型假设每个细胞的边界可以用多个高斯分布组合而成的模型来近似,从而有效地捕捉到细胞的形状和大小变化。活动网格利用一个动态调整的网格系统来覆盖图像中的细胞,每个网格点都可以独立移动,以适应细胞边界的变化,从而更精确地跟踪细胞位置和形态的演变。活动轮廓方法通过数学上定义的曲线(轮廓线)来描述和跟踪对象的边界。这些曲线是动态调整的,能够随着细胞的运动和形态变化而变化,从而实现对细胞轮廓的识别及跟踪。而隐式模型,如 Dzyubachyk 采用水平集方法来描述

细胞轮廓^[30]。水平集方法用于在连续的维度空间中捕捉界面和曲面的演化。在细胞跟踪中，它通过计算和更新代表细胞边界的等高线来跟踪细胞的移动和变化。

但是参数化方法的有效性高度依赖于参数的选择，而隐式方法的计算成本较高。因此在细胞聚集、形态变化频繁或数量众多的情况下，这些算法的性能往往不够理想。

当前细胞跟踪方法主要采用基于检测的策略，该方法主要分为两个阶段：细胞检测与细胞关联。在细胞检测阶段，通过目标检测网络识别细胞，这一步骤能够实现高精度的细胞识别；在细胞关联阶段，利用实时或跨多帧的离线关联方式，为已识别的细胞分配唯一的身份 ID，从而实现连续帧间的细胞跟踪。

刘敏于 2019 年提出了一种局部图匹配算法^[31]，此算法通过分析密集植物细胞的空间拓扑结构进行跟踪，并采用迭代搜索策略，从种子细胞对开始扩展匹配关系。该方法结合了局部图匹配和基于 CNN 的相似性学习，利用时空上下文信息及细胞对的相似性来确定种子细胞对。

Payer 采用基于嵌入的全卷积网络实现实例分割^[32]，融合了余弦相似度的嵌入损失和递归全卷积网络。算法将卷积门控循环单元(ConvGRU)集成至堆叠沙漏网络(Stacked Hourglass Network)^[33]中，以利用视频中的时间信息，并通过余弦相似度生成的像素级嵌入向量进行聚类，实现视频帧间的细胞跟踪。

DeLTA 算法^[34]采用 U-Net 网络^[35]进行图像分割，以识别单个细胞及其形态特征。然后使用另一个 U-Net 模型跟踪时间延迟显微镜图像中各帧的细胞位置，记录细胞分裂事件并跟踪细胞谱系。在细胞分割过程中，模型采用像素加权二元交叉熵损失函数，通过为不同的像素分配不同的权重，专注于学习过程中关键区域，如细胞边缘。

CellTrack R-CNN^[36]将细胞分割与细胞跟踪集成于一个端到端深度学习框架中，其中使用 Mask R-CNN 网络^[37]进行细胞检测和分割，而细胞跟踪则通过 Siamese 网络^[38]实现。CellTrack R-CNN 在跟踪分支中加入了空间信息，获得可学习的细胞实例相对位置编码，并将其与视觉特征融合，从而提高了跟踪性能。

1.3 本文研究内容及创新点

显微镜成像技术的发展极大地推进了生物医学研究的进展，特别是在空间-时间细胞成像方面。通过观察细胞迁移活动，研究人员能够构建细胞谱系并分析其形态的变化。特别地，观察化学物质刺激下的细胞迁移，能够为理解某些肿瘤疾病与异常细胞行为之间的关联性提供新的视角，进而有助于揭示相关致病因子的病理机制。然而，由于显微图像的低信噪比、有限的时空分辨率及细胞形态、位置和运动轨迹的不稳定性，传统的多目标识别与跟踪算法面临着精确定位和跟踪细胞的难题。

本文的研究内容包括三个方面：细胞检测定位、细胞跟踪以及细胞活性分析。首先设计了基于轮廓注意力的渐进式细胞检测(Contour Attention-based Progressive Cell Detection, CAPCD)网络，用于定位检测细胞；其次，提出基于混合特征自适应匹配的 HFM-Tracker(Hybrid Features Matching-based Tracker)细胞跟踪算法，在数据关联阶段通

过自适应代价矩阵(Adaptive Cost Matrix, ACM)整合加权细胞形态特征与混合运动特征,以关联细胞的运动轨迹,采用卡尔曼滤波器结合细胞的历史状态和当前观测运动量来预测未来状态,实现准确的轨迹跟踪;最后,分析了不同浓度过氧化氢刺激下的 MCF-7 肿瘤细胞行为特征变化,探究过氧化氢刺激对细胞活性的影响,深入研究了肿瘤细胞迁移特性及其相关的生物学过程。

本文的创新点包括:

(1) 设计了基于轮廓注意力的 CAPCD 网络,首先构建了基于中心距离热力图编码的初始轮廓构建模型,用于检测细胞的初始目标框;然后提出了基于轮廓注意力的轮廓偏移预测网络通过多次迭代回归来精确捕捉细胞的轮廓信息,引入轮廓注意力模块,使模型在轮廓变形过程中专注回归非细胞轮廓点。在模型训练过程中,设计基于轮廓点监督的偏移预测损失函数训练模型,使其专注于细胞相邻轮廓点,提高模型性能。

(2) 设计了基于自适应特征匹配的 HFM-Tracker 细胞跟踪算法,在数据关联阶段通过自适应代价矩阵模块加权细胞形态特征和混合运动特征,以关联细胞的运动轨迹。形态特征通过基于尺度不变的 Hu 不变矩进行提取,而混合运动特征则结合 GIoU、欧氏距离和面积比进行度量,并设计自适应特征匹配策略计算代价矩阵。利用卡尔曼滤波器综合细胞的过往状态和当前检测到的运动信息,预测细胞未来位置,从而实现精准的细胞跟踪。

(3) 基于含不同浓度过氧化氢培养的 MCF-7 肿瘤细胞跟踪实验结果,综合分析细胞的形态特征与迁移运动变化,探究过氧化氢刺激对肿瘤细胞迁移特性和细胞活性的影响,分析结果表明过氧化氢会显著降低细胞活性:过氧化氢浓度越高,细胞迁移速度越慢,活性降低,且在一定过氧化氢浓度下,会直接导致细胞死亡,这些数据为肿瘤疾病的研究和诊断提供了重要依据,对生物医学的基础研究具有重要意义。

1.4 本文组织结构

本文共有六个章节,各个章节的内容架构如下:

第 1 章:绪论。本章主要详细介绍多细胞跟踪的研究背景,并阐述了细胞图像研究的意义和研究价值,分析列举了国内外在多目标跟踪和细胞跟踪领域的研究现状,最后概述了本课题主要的研究内容和创新点,并简要介绍了本文的组织结构。

第 2 章:多目标跟踪相关算法与数据集介绍。本章主要介绍了多目标跟踪的相关理论和研究现状,探讨了基于检测的跟踪方法与联合检测的跟踪方法两种不同的跟踪范式;并介绍了论文中用到的自制细胞数据集和公开细胞数据集。

第 3 章:基于轮廓注意力的渐进式细胞检测网络。本章基于 Snake 算法并采用扩张圆形卷积以充分利用细胞轮廓,提出了基于轮廓注意力的 CAPCD 网络。通过构建轮廓注意力图,使模型更加专注于回归非细胞边界点,并多次迭代网络对细胞轮廓精细化回归,提高了细胞检测的准确度。

第4章：基于混合特征自适应匹配的细胞跟踪算法。为了准确跟踪连续帧间细胞的轨迹，在数据关联阶段，采用 ACM 模块整合加权细胞形态特征与混合运动特征来关联细胞运动轨迹，设计自适应匹配策略计算代价矩阵，充分利用细胞多模态特征，有效地关联细胞的运动轨迹。

第5章：细胞定位跟踪算法的应用。本章基于提出的细胞跟踪算法，对处于不同状态的 MCF-7 肿瘤细胞（培养液中加入不同浓度的过氧化氢）数据集进行实验，从多个特征维度探究过氧化氢对细胞活性和迁移特性的影响，深入研究细胞的迁移特性及其与细胞迁移相关的生物学过程，以此助力肿瘤疾病的研究和诊断。

第6章：总结与展望。本章总结了本文所提出的细胞检测算法和跟踪算法，并分析了研究过程中遇到的一些不足。同时，对多细胞跟踪的未来研究方向和潜在改进点进行了展望。

第2章 多目标跟踪相关算法与数据集介绍

本章主要介绍多目标跟踪(Multiple Object Tracking, MOT)领域的主流算法和用到的数据集。详述国内外在该领域的研究现状与成果,围绕两种经典的多目标跟踪范式,从不同的算法思想展开,通过分析对比传统目标跟踪算法与当前研究前沿方法,为后续提出本文的细胞跟踪算法做技术铺垫。最后介绍了本研究使用的数据集,包括自制数据集和公开数据集。

2.1 多目标跟踪算法概述

单目标跟踪(Single Object Tracking, SOT)主要侧重于设计复杂的外观模型或运动模型,以应对尺度变化、旋转和光照变化等因素。与之相比,多目标跟踪除了需要应对这些挑战之外,还面临两个挑战:识别随时间变化的目标数量以及保持它们的身份 ID 信息。随之出现的问题还包括频繁发生的遮挡、目标轨迹的开始和结束、相似性度量,以及多个目标之间的交互作用。

多目标跟踪任务主要涉及三个步骤:首先是识别和定位场景中的多个目标;其次是在连续帧中跟踪这些目标的身份 ID 信息,以区分不同的目标;最后,在处理视频数据时,需要跟踪目标的移动轨迹。被跟踪的目标种类繁多,包括但不限于街道上的行人^[39, 40]、道路上的车辆、球场上的运动员或动物群体(鸟类、蚂蚁、鱼类、细胞^[41, 42]、蜜蜂等)。此外,“多个目标”也可以指单一实体的不同部分^[43]。

基于深度学习的 MOT 算法的分类如图 2.1 所示,主要分为基于检测的跟踪(Detection-based Tracking, DBT)和联合检测跟踪(Joint Detection Tracking, JDT)。随着深度学习技术在视觉多目标跟踪相关任务中的广泛应用^[44],目前基于深度学习的 MOT 技术框架主要采用 DBT 方法,即先通过目标检测器对图像帧检测得到目标检测信息,再基于检测结果进行数据关联以实现多目标跟踪,这种方法充分利用了深度学习在目标检测方面的优势。在 DBT 框架中,特征提取等子模块可以与目标检测网络结合,实现更紧密的集成。这种基于 DBT 子模块融合的方法可以进一步演化为 JDT 模式,其中检测和跟踪在同一深度神经网络中联合优化,以提高效率和性能。




图 2.1 基于深度学习的多目标跟踪算法分类

Fig 2.1 Classification of deep learning based multi object tracking algorithms

2.2 基于检测的跟踪算法

DBT 算法主要分为两个核心部分：目标检测阶段和数据关联阶段^[45]。如图 2.2 所示，在目标检测阶段，算法从视频帧中准确地识别和定位目标，为后续跟踪过程奠定基础。在数据关联阶段，算法通过比较连续帧中目标的特征，如外观和运动信息，来保持目标的身份 ID 信息，从而实现对其运动轨迹的准确跟踪。

在目标检测阶段，核心任务是从复杂的视频帧数据中准确识别和定位出各个目标。这一阶段利用深度学习模型的强大能力，对输入的视频帧进行分析，以检测出存在的目标。通过精确的边界框标识，每个目标被清晰地定位，为跟踪过程奠定了基础。目标检测不仅需要高精度，还要求能够处理各种挑战，如遮挡、快速移动、尺度变化和光照条件变化等，确保能够在各种环境下有效识别目标。

在数据关联阶段，算法需要在连续的视频帧中跟踪同一目标的运动轨迹。这一过程需要对前一阶段检测到的目标保持其身份 ID 信息，即确定哪些目标在不同帧中是相同的。通过结合它们的外观特征和运动模式分析目标之间的相似度，计算出最有可能的目标匹配，实现跟踪。数据关联阶段的挑战在于处理目标间的交互、遮挡以及进入或离开视野的情况。




图 2.2 基于 DBT 框架的算法流程图

Fig 2.2 Flowchart of the algorithm based on the DBT framework

2.2.1 目标检测算法

在 DBT 领域中，目标检测不仅是整个跟踪过程的前提，也是提升整体跟踪性能的重要因素^[46]。目标检测的准确性直接关系到跟踪算法能否正确初始化目标的跟踪状态，以及在整个跟踪过程中是否能持续准确地更新这些状态。因此，高效且准确的目标检测算法是提升多目标跟踪性能的关键。

目标检测技术的核心挑战不仅需要识别图像中是否存在目标物体，更重要的是精确定位物体的位置。目标检测的主要步骤包括目标分割、提取和识别。其中，目标分割是识别图像中的潜在候选区域，通过分析图像的特征来划分出可能包含目标的区域；特征提取则是对这些候选区域进行进一步处理，提取用于后续识别的关键信息；而目标识别则是从众多候选框中识别出实际的目标物体。

在 2014 年之前，目标检测领域主要依赖于基于特征的传统算法进行目标的识别与定位。然而，自 2014 年起，深度学习算法的兴起改变了该领域的研究和应用方向，大大提升了目标检测的准确度与效率。深度学习技术的引入，使得目标检测方法在处理复杂视觉数据方面的能力得到了极大增强。

在基于深度学习的目标检测领域，可以将现有算法分为两大类：两阶段检测器和单阶段检测器。

两阶段检测器涉及两个主要步骤：目标区域的生成和对生成区域内目标的分类。在第一步骤中，算法通过机器学习技术或深度神经网络来识别推荐可能含有目标的区域；在第二步骤中，对这些建议区域内的特征进行深入分析和分类，以实现目标的准确识别。此类检测器采用由粗糙到精细的策略，先提高算法的召回率，再在此基础上细化定位，区分目标与非目标的能力较强。虽然两阶段检测器在检测精度上表现优异，但其较慢的处理速度和较高的复杂性限制了其在实际应用场景中的适用性。

相比之下，单阶段检测器设计用于在一次推理过程中直接识别出所有目标，无需预先生成候选区域。此类检测器因其较快的处理速度和较低的复杂度，在实时性能和部署便捷性方面具有较大优势。然而，当面对高密度小物体的检测任务时，单阶段检测器往往性能表现不如两阶段检测器。

(1) 两阶段目标检测算法。两阶段目标检测器的基本结构如图 2.3 所示，在第一阶段，算法生成多个候选区域，这些区域被认为很可能包含目标。然后，在第二阶段，算法对这些候选区域进行详细分析，提取特征并执行分类，以确定每个区域是否包含目标以及目标的类别。




图 2.3 两阶段目标检测算法的基本结构

Fig 2.3 Basic structure of two-stage target detection algorithm

2014 年，Ross 提出了结合 CNN 特征的区域检测方法(Region with CNN features, R-CNN)^[47]，R-CNN 网络框架如图 2.4 所示。算法主要包括以下步骤：首先输入一张待测图像，利用选择性搜索算法从中生成大约 2000 个候选框。然后将每个候选框缩放到固定大小（例如 227×227 像素），以便在 CNN 中统一提取特征向量。此后，这些特征向量被送入 SVM(Support Vector Machine, SVM)分类器及全连接网络中，以进行目标分类并对边界框进行精细调整。但是当选择性搜索算法提取每个候选框时，CNN 需要前向传播进行特征提取，导致实时性能不足。此外，在处理不同尺寸的候选区域特征时，会统一调整特征图至固定尺寸以适配全连接层或 SVM 分类器，种尺寸调整方法会导致图像的形变和特征信息的部分丢失，影响目标检测性能。




图 2.4 R-CNN 网络框架图

Fig 2.4 Diagram of the R-CNN network framework

为了解决 R-CNN 网络在处理候选区域特征时需要重复输入至 CNN 以及必须对输入图像进行固定尺寸调整的限制, He 等人提出了空间金字塔池化网络(Spatial Pyramid Pooling Network, SPPNet)^[48, 49]。SPPNet 通过引入一种创新的池化策略, 允许网络处理任意尺寸的输入图像, 从而避免了因调整图像尺寸导致的形变和特征信息损失问题。对于重复输入 CNN 特征的问题, 作者提出了名为 SPP Layer 的模块, 如图 2.5 所示, 改变了特征提取流程, 允许直接从整张图像中提取特征, 随后结合区域提案算法确定全图特征的具体区域, 这样便无需对每个候选区域分别执行特征提取, 大幅度提升了效率。

SPP Layer 的引入不仅使得 CNN 能够处理不同尺寸的输入图像, 而且还能为任意区域生成固定长度的特征表示, 消除了因重新缩放带来的问题。在 SPPNet 模型中, 执行目标检测仅需对整张图像进行一次特征映射计算, 后续可直接为任意区域产生固定长度的表示, 从而避免了重复的卷积特征计算。这种方法不仅使得检测速度相较于 R-CNN 提高了 20 倍以上, 而且还提高了检测精度。




图 2.5 SPP-Net 网络框架图

Fig 2.5 SPP-Net network framework diagram

2015 年, Ren 等人提出了 Faster RCNN^[50], 这也是首个接近实时的深度学习检测器。Faster RCNN 包括三个部分, 如图 2.6 所示: 首先, 利用 CNN 对输入图片进行特征提

取, 以获得特征图; 接着, 通过 RPN 网络生成目标的候选框; 最终, 借助 ROI Pooling 层及随后的分类网络, 完成目标的类别判定, 并输出分类结果。

Faster RCNN 引入了区域建议网络(Region Proposal Network, RPN), 通过与 CNN 共享全图的特征映射, 直接在特征映射上滑动小网络, 这个小网络在每个位置同时预测多个区域边界和对象分数。具体来说, RPN 为每个位置生成多个大小和比例不同的候选框, 称为锚框(Anchor Boxes)。通过这种方式, RPN 能够在单一的网络中同时预测对象的边界和对象性分数, 提高了区域提案的生成速度, 降低网络的运算量。




图 2.6 Faster RCNN 算法流程图

Fig 2.6 Flowchart of the Faster RCNN algorithm

2017 年, Lin 等人提出了特征金字塔网络(Feature Pyramid Networks, FPN)^[51], 改进了传统的深度学习检测模型。在 FPN 出现之前, 绝大多数基于深度学习的检测器主要依赖于网络顶部的单一尺度特征映射来进行目标检测。虽然 CNN 深层的特征映射对于识别物体的类别非常有效, 但它们在精确位置定位时往往表现不佳, 特别是对于小尺寸物体的检测。

FPN 通过引入一种具有横向连接的自顶向下的架构, 实现了在不同尺度上构建同时具备丰富高级语义信息的特征映射, 网络结构如图 2.7 所示。这种方法允许网络不仅在顶层, 而且在多个层级上进行目标检测, 每个层级处理不同尺度的物体。因此 FPN 有效地弥补了传统目标检测模型在检测多尺度物体时的不足, 提高了模型对于各种尺寸物体的检测性能。




图 2.7 FPN 网络结构示意图

Fig 2.7 Schematic diagram of FPN network structure

(2) 单阶段目标检测算法。在单阶段检测器的领域中，边界框的预测直接在没有区域建议步骤的图像上进行，这大大提高了检测的速度。单阶段检测器的基本结构如图 2.8 所示，其核心优势在于简化了检测流程，实现了高效的速度与性能的平衡。




图 2.8 单阶段目标检测算法的基本框架

Fig 2.8 Basic framework of single-stage target detection algorithm

SSD 算法(Single Shot Multibox Detector, SSD)^[52]由 Liu 等人于 2015 年提出，是一种经典的单阶段目标跟踪算法，其网络结构如图 2.9 所示。该算法的网络架构主要包括三个部分：特征提取网络、目标检测器和非极大值抑制。特征提取网络通过六个不同尺度的特征层来从输入图像中提取特征，从而生成特征图。紧接着，目标检测器采用两组卷积核分别对每个特征图进行处理，产生包含位置和类别信息的预测框，实现对不同尺度目标的检测。对这些预测框中的类别信息进行打分，并利用 NMS 算法筛选出那些类别置信度高于特定阈值的预测框，作为最终的检测结果。SSD 算法的创新之处在于其摒弃了传统的候选框方法，转而预测与每个像素点相关联的锚框，同时对目标的类别和位置进行回归分析。这种方法不仅提高了检测的精度，也大大加快了检测速度。




图 2.9 SSD 网络结构框架图

Fig 2.9 Framework diagram of SSD network structure

YOLO(You Only Look Once)系列算法^[53-59]最早由 Joseph 等人于 2015 年提出，受区域建议网络的启发，与两阶段目标检测算法不同，YOLO 算法在单次图像处理中实现了目标的检测与分类，极大的提升了目标检测算法的检测速度。这种创新不仅引领了目标检测技术的新范式，也拓展了其应用领域，随着技术的不断发展，国际上对 YOLO 算法不断更新改进，目前已进展至 YOLOv9，使 YOLO 算法在保证速度的同时提升了检测的精确度。

YOLOv1^[56]将目标检测作为单个回归问题来处理，通过单一的神经网络结构来同时

处理图像的多个区域并预测边界框及其对应的概率，其网络结构如图 2.10 所示。该模型采用 GoogleNet 作为骨干网络，对输入图像进行下采样和特征提取。通过将图像划分为网格，每个网格负责预测数个边界框的方式，来评估这些边界框中存在目标的置信度以及目标类别的概率。YOLOv1 的核心理念是将目标检测转化为直接的回归问题，对全图进行一次特征提取，并同时预测边界框和目标类别。该方法具备全图像输入的优势，提取特征并预测目标类别与边界框。此外，模型使用了交并比(Intersection over Union, IoU)和置信度阈值来筛选边界框候选，并应用 NMS 来优化最终的检测结果。但相对于当时的两阶段检测器，其小目标的定位精度上不如传统两阶段检测器。




图 2.10 YOLOv1 网络框架图

Fig 2.10 YOLOv1 network framework diagram

随后，YOLO 系列不断迭代更新：YOLOv2^[53]专注于改善小目标检测；YOLOv3^[57]在提高精度和速度方面取得了进一步优化；YOLOv5^[58]增强了模型的通用性和易用性。YOLOv9^[59]引入了可编程梯度信息(Programmable Gradient Information, PGI)和广义高效层聚合网络(Generalised Efficient Layer Aggregation Network, GELAN)，这些特性增强了模型的学习能力并确保在检测过程中重要信息的保留，从而实现更高的准确性。

虽然单阶段检测器检测速度快、网络结构简单，但是其检测精度多年来一直落后于两阶段探测器。针对这一问题，Lin 等人在 2017 年提出了 RetinaNet^[60]。他们认为训练过程中前景对象和背景之间的类别不平衡是影响检测精度的主要原因。为此，在 RetinaNet 中引入了一个新的损失函数 Focal Loss，该函数在形式上通过调整易分类样本的贡献权重，减少了对多数简单负样本（背景）的关注，同时增加了对那些难以正确分类的样本（例如小目标或部分遮挡的目标）的重视。Focal Loss 的计算如式(2-1)所示：

$$L_{fl} = \begin{cases} -(1 - \hat{p})^\gamma \log_2(\hat{p}), & \text{if } y=1 \\ -\hat{p}^\gamma \log_2(1 - \hat{p}), & \text{if } y=0 \end{cases} \quad (2-1)$$

其中， $\hat{p}$ 为模型对于每个类别正确预测的概率， γ 是调节难易分类样本权重的参数。

Zhou 等人在 2019 年提出了 CenterNet^[27]，与传统依赖锚框进行目标分类和位置回归的方法不同，CenterNet 遵循基于关键点的检测范式，不需要预设大量参考框，同时舍去了网络的后处理步骤，如基于组的关键点分配和 NMS，实现了一个完全端到端的检测网络，其网络结构如图 2.11 所示。CenterNet 的核心原理是采用主干网络(如 ResNet、Hourglass 等)来提取图像的深度特征映射。模型将目标的中心点作为关键点进行检测，每个中心点对应一个目标的中心。网络输出的是一个热力图(Heatmap)，其中每个像素的值代表该位置作为某一目标中心的置信度。除此之外，CenterNet 还预测每个目标的尺

寸，通过输出宽度和高度的偏移量，从而精确定位每个目标的边界框。




图 2.11 CenterNet 的网络结构图

Fig 2.11 Network structure diagram of CenterNet

2.2.2 数据关联算法

在 MOT 系统中，数据关联主要是将目标检测模型输出的检测目标与跟踪网络中的现有轨迹进行匹配。该过程本质上是一个寻找最优解的问题，以准确识别并跟踪物体的运动路径，同时需要考虑遮挡、目标变形以及尺寸比例变化等多种因素的影响。SORT 算法^[18]通过融合卡尔曼滤波器的预测能力和匈牙利算法的最优匹配策略，在跟踪速度和精度之间取得了良好的平衡，是一种广泛采用的数据关联算法。

卡尔曼滤波器^[61]作为一种线性动态系统状态估计的算法框架，广泛应用于导航系统、控制系统以及计算机视觉领域，特别是在目标跟踪和状态预测方面。通过迭代的预测、观测和修正过程，卡尔曼滤波器有效地降低了噪声干扰，实现了对系统状态的精确估计。该算法基于两个核心前提：一是系统状态的线性表达，二是测量误差符合高斯分布。在此基础上，卡尔曼滤波器依据最小二乘法原则，提供了对系统状态的最优估计^[62]。

卡尔曼滤波算法主要分为预测和更新两个阶段。在预测阶段，算法利用先前状态的修正估计来预测当前状态。更新阶段则结合卡尔曼增益和新的观测数据来修正先前的预测，从而得到更精确的当前状态估计。通过这种迭代方式，算法能够不断地改进对系统状态的估计。

具体而言，卡尔曼滤波器建立在以下模型上：系统状态 x 和观测状态 z 通过线性关系连接，其中状态转移矩阵 A 描述了系统状态随时间 k 的变化，观测矩阵 H 则揭示了在时间 k 的观测值与系统状态之间的联系，如式(2-2)、式(2-3)所示：

$$x_{k+1} = A_k x_k + w_k \quad (2-2)$$

$$z_k = H_k x_k + v_k \quad (2-3)$$

其中， k 代表离散时间步， w 和 v 分别代表影响系统状态和观测的高斯过程噪声和测量噪声，其协方差矩阵分别定义为 Q 和 R ，具体计算方式如式(2-4)、式(2-5)所示：

$$Q_k = E[w_k w_k^T] \quad (2-4)$$

$$R_k = E[v_k v_k^T] \quad (2-5)$$

根据系统状态的更新，能够推导出当前系统状态的预测估计 $x_{k|k}$ ，如式(2-6)所示：

$$x_{k|k} = A_{k-1} x_{k|k-1} \quad (2-6)$$

其中， $x_{k|k-1}$ 为基于上一状态修正后的估计值，即卡尔曼滤波的估计，而 $x_{k|k}$ 表示当前状态的预测值。

从先前状态 $P_{k-1|k-1}$ 到当前预测状态 $P_{k|k}$ 的转换公式如式(2-7)-式(2-11)所示:

$$e_{k|k-1} = x_k - x_{k|k-1} \quad (2-7)$$

$$e_{k|k} = x_k - x_{k|k} \quad (2-8)$$

$$P_{k|k} = E[e_{k|k} e_{k|k}^T] \quad (2-9)$$

$$P_{k|k-1} = E[e_{k|k-1} e_{k|k-1}^T] \quad (2-10)$$

$$P_{k|k} = A_k P_{k-1|k-1} A_k^T + Q_{k-1} \quad (2-11)$$

式(2-7)-式(2-11)中 x_k 代表真实系统状态, $e_{k|k}$ 和 $e_{k|k-1}$ 为估计误差。 $P_{k|k}$ 和 $P_{k|k-1}$ 分别为针对预测估计和修正估计的误差定义的误差协方差矩阵。

卡尔曼滤波器通过最小化修正后估计误差的协方差之和来寻找最优的状态估计, 关键在于需要确定一个卡尔曼增益矩阵 K_k , 以更新系统状态。卡尔曼增益的计算目标是使得修正后的估计误差协方差之和最小化。卡尔曼增益 K_k 、当前状态的修正估计 $x_{k|k}$ 及其误差协方差 $P_{k|k-1}$ 的更新公式如式(2-12)-式(2-14)所示:

$$K_k = P_{k|k} H_k^T (H_k P_{k|k} H_k^T + R_k)^{-1} \quad (2-12)$$

$$x_{k|k} = x_{k|k-1} + K_k (z_k - H_k x_{k|k-1}) \quad (2-13)$$

$$P_{k|k-1} = (I - K_k H_k) P_{k|k} \quad (2-14)$$

其中, I 为单位矩阵, z_k 为实际观测值。

在多目标匹配问题中, 通常需要处理两种类型的目标: 一种是当前帧内检测到的目标, 另一种是来自上一帧待匹配的目标。匹配算法的目标是在这两组目标之间建立一对一的匹配关系, 同时保证同组内的目标不会相互匹配。

匈牙利算法^[63]是一种高效的关联算法, 用于解决最优二分图匹配问题。算法将匹配问题转化为一个图论问题, 将每个目标视作图中的一个顶点, 而一对一的匹配关系则通过一条连接两个顶点的边来表示。两组目标便构成了图中的两个独立顶点集合, 每个集合内的顶点均与另一个集合中的所有顶点通过边相连。

基于这一结构, 能够构建一个带权重的完全二分图, 其中的权重通常代表匹配的可能性或成本, 如图 2.12 所示, $X_1 \sim X_4$ 为待匹配的目标, $Y_1 \sim Y_4$ 为新检测的目标, 每条边代表一个匹配关系, 边的权值为两个目标的相似度, 基于此构建关联代价矩阵。接下来, 匈牙利算法通过多种操作对关联矩阵进行调整, 如行列减法和行列覆盖, 直至找到成本最低的匹配方案。




图 2.12 二分图匹配示意图

Fig 2.12 Schematic diagram of bipartite graph matching

SORT 算法框架如图 2.13 所示，算法主要采用卡尔曼滤波器的预测能力和通过计算检测帧与现有轨迹之间相关性的数据关联技术。算法的核心包括 IoU 匹配过程和卡尔曼预测更新过程。在实践中，SORT 依赖于目标检测模型来识别图像中的所有目标，并通过卡尔曼滤波器预测目标在当前帧中的位置。随后，利用匈牙利算法基于 IoU 分配成本矩阵来求解上一帧预测轨迹与当前帧检测到的目标之间的最佳匹配，最终通过卡尔曼滤波更新轨迹信息。




图 2.13 SORT 算法流程示意图

Fig 2.13 Schematic diagram of the SORT algorithm flow

2.3 联合检测的跟踪算法

在多目标跟踪任务中，基于深度学习的 DBT 算法通常将检测与跟踪作为两个独立的处理阶段进行。这种分阶段的处理方式虽然在逻辑上清晰，但往往导致算法结构复杂，各模块之间的耦合度低。为了优化这一流程，研究者提出了集成检测与跟踪的 JDT 算法。JDT 算法的核心思想是在检测与跟踪阶段之间实现参数和权值的共享，从而使两个阶段不再是完全独立的，而是能够相互协作和优化。

2019 年, Bergmann 等人提出了 Tracktor++ 算法^[64], 创新性的融合了检测和跟踪功能。Tracktor++ 的算法框架如图 2.14 所示, Tracktor++ 的核心创新在于直接利用前一帧的检测结果, 通过检测器的回归分支来预测当前帧中目标的位置。这种方法的优点包括两个方面: 首先, 它避免了使用专门的跟踪算法, 简化了整个处理流程; 其次, 由于测试阶段不需要复杂的优化计算, 因此非常适合在线训练和实时应用。




图 2.14 Tractor++算法流程图

Fig 2.14 Flowchart of Tractor++ algorithm

Tracktor++选用 Faster R-CNN 作为目标检测器，它采用 ResNet-101+FPN 作为骨干网络，该结构能够对每帧图像进行不同尺度的特征提取，有效地识别出不同大小的目标。此外，为了降低身份 ID 切换的频率并确保系统的实时性，Tracktor++引入了基于 Siamese 网络的 ReID 模型来评估目标之间的相似度。

在跟踪过程中，Tracktor++首先利用 $t-1$ 帧的目标边界框，通过边界框回归来预测第 t 帧中目标的新位置。在 Faster R-CNN 框架中，此步骤涉及将当前帧的特征图与 $t-1$ 帧的目标框 b_t 进行 ROI 池化层操作，随后输入到后续的池化、分类回归网络中，进一步微调边框得到 D_t 。边界框 b_t 的生成方式如式(2-15)-式(2-17)所示：

$$b_t = \begin{cases} D_0, & \text{if } t = 0 \\ b_{t_{\text{sub}1}} \cup b_{t_{\text{sub}2}}, & \text{otherwise} \end{cases} \quad (2-15)$$

$$b_{t_{\text{sub}1}} = f(b_{t-1}, \mathbf{F}\mathbf{M}_t) \quad (2-16)$$

$$b_{t_{\text{sub}2}} = g(D_t, f(b_{t-1}, \mathbf{F}\mathbf{M}_t)) \quad (2-17)$$

其中， $\mathbf{F}\mathbf{M}_t$ 表示第 t 帧的特征图。

在式(2-15)中，初始帧直接采用调整后的边框 D_0 作为结果，并为每个边框分配一个 ID，即 $b_0 = D_0$ 。对于后续帧， b_t 分为两部分，一部分是继承自前一帧的目标 $b_{t_{\text{sub}1}}$ ；另一部分为新识别的目标 $b_{t_{\text{sub}2}}$ 。

式(2-16)描述了 $b_{t_{\text{sub}1}}$ 的生成过程。该函数将前一帧的跟踪边框与当前帧的特征图 $\mathbf{F}\mathbf{M}_t$ 结合，识别并更新当前帧的目标边框。这一步骤通过去除得分低或冗余的检测框，保持目标跟踪的连续性，并维持前一帧目标的 ID 信息。

式(2-17)描述了 $b_{t_{\text{sub}2}}$ 的生成过程。 $b_{t_{\text{sub}2}}$ 主要处理从前一帧继承下来的目标。首先使用 NMS 去除 $b_{t_{\text{sub}1}}$ 中与 D_t 重复的部分，再通过 ReID 评估目标间的相似度。使用匈牙利算法匹配相似度高的目标，并为它们分配 ID，将它们从未激活队列中移除。这一步骤能够使网络持续跟踪被遮挡的目标，减少 ID 切换。未匹配的 D_t 中的目标将被视为新的跟踪对象，并分配新的 ID。

Zhou 等人提出了 CenterTrack 算法^[26]，该算法通过将传统的基于锚点的 Faster R-CNN 模型替换为无锚点的 CenterNet 模型，实现对目标中心点的精确检测和跟踪，网络框架如图 2.15 所示。不同于传统的跟踪策略，CenterTrack 算法通过将前一帧图像信息并入网络输入，有效地利用了时序信息，将 MOT 任务简化为通过目标中心点进行跟踪的问题。




图 2.15 CenterTrack 网络框架示意图

Fig 2.15 Schematic diagram of the CenterTrack network framework

CenterTrack 选用深层聚合网络(Deep Layer Aggregation, DLA)^[65]作为其骨干网络，以强化特征提取和融合的能力，同时采用 Adam 优化器^[66]以提高训练效率和模型收敛速

度。该算法通过预测目标的中心点变化，直接在连续帧间建立目标的关联，从而避免了复杂的数据关联过程。此方法不仅简化了跟踪流程，而且通过直接关注目标的中心点，降低了模型对锚点设定的依赖。

尽管 CenterTrack 实现了较高跟踪精度，但该算法在处理长期跟踪任务时，存在着较频繁的身份 ID 切换问题。主要是由于模型在处理遮挡或目标快速移动情况时高度依赖持续性识别，以及其在目标重现时的识别和关联能力不足。

2.4 数据集介绍

本文自制细胞数据集采集自南京大学分子传感与图像中心，涵盖了在不同条件下，通过实时细胞培养技术获得的细胞图像。实验中使用的细胞类型为 MCF-7 人体乳腺癌细胞系，并在含有 RPMI1640 培养基、10%的胎牛血清和 1%的抗生素（包括青霉素和链霉素）的 24 孔板中培养。细胞的培养条件是 37 摄氏度和 5%二氧化碳的恒温恒湿培养箱中。为了采集延时细胞图像，使用了德国进口的 zenCELL owl 培养箱封闭显微镜。为了模拟不同的实验环境，MCF-7 细胞的培养液中分别添加浓度为 0 μM 、50 μM 、100 μM 、250 μM 、500 μM 、1000 μM 的过氧化氢，每组图像包括 144 张延时拍摄的图像，分辨率为 2588 $\times$ 1942 像素，对应实际尺寸比例为 1:0.488 μm 。每 10 分钟采集一次图像，记录时间总计 24 小时。自建的 MCF-7 肿瘤细胞数据集图像示例图如图 2.16 所示。




图 2.16 MCF-7 肿瘤细胞图像序列示意图

Fig 2.16 Schematic of the MCF-7 tumour cells image sequence

本研究从含 250 μM 过氧化氢浓度的 MCF-7 肿瘤细胞数据集中选取了共 70 幅图像，按 8:1:1 的比例分为训练集、验证集和测试集，以便对模型进行准确评估。具体而言，训练集由 56 张图像组成，涵盖了 5574 个细胞实例；验证集包含 7 张图像，含有 694 个细胞；测试集包含 7 张图像，总计 680 个细胞实例。所有这些图像均来源于在含 250 μM 过氧化氢浓度环境下培养的 MCF-7 人乳腺癌细胞系，记录了细胞的自然生长、收缩和分裂现象。

本研究还采用了由荷兰伊拉斯谟医疗中心的 Cappellen 博士提出的 DIC-C2DH-HeLa 细胞公共数据集，用以进一步评估算法的有效性。数据集主要由平板玻璃上 HeLa 细胞的差分干涉对比(Differential Interference Comparison, DIC)图像组成，每张图像的分辨率为 1100 $\times$ 700 像素，对应实际尺寸比例为 1:0.19 μm ，每 10 分钟记录一次图像。本研究从 DIC-C2DH-HeLa 细胞公共数据集中选取了共 90 幅图像，按 8:1:1 的比例分为训练集、验证集和测试集。具体而言，训练集由 72 张图像组成，涵盖了 3888 个细胞实例；验证

集包含 9 张图像，含有 540 个细胞；测试集包含 9 张图像，总计 422 个细胞实例。Fluo-C2DL-Huh7 公共细胞数据集示意图如图 2.17 所示。



图 2.17 Fluo-C2DL-Huh7 数据集示意图

Fig 2.17 Schematic of the Fluo-C2DL-Huh7 dataset

2.5 本章小结

本章主要介绍了多目标跟踪相关的理论算法，以及研究所用数据集。多目标跟踪算法又分为基于检测的跟踪算法和联合检测的跟踪算法来介绍，对于基于检测的跟踪算法，详细介绍了基于深度学习的目标检测算法和数据关联算法，并在其中分别介绍了两阶段目标检测算法和单阶段目标检测算法。最后介绍了本文所用的两种数据集，包括自制 MCF-7 肿瘤细胞数据集以及 DIC-C2DH-HeLa 细胞公共数据集。

第3章 基于轮廓注意力的渐进式细胞检测网络设计

在过去几年中,目标检测算法发展迅速,尤其是两阶段的目标检测算法在深度学习技术的助力下,已经达到了较高的检测精度。然而,在特定等应用场景,如本文所用到的肿瘤细胞数据集,面临着一定的挑战。特别是考虑到细胞数量众多、形态多样性以及相互之间的遮挡等因素,以往的目标检测算法难以有效适应。本文在现有目标检测算法的基础上,针对上述问题,本文提出了一种基于轮廓注意力的渐进式细胞检测(Contour Attention-based Progressive Cell Detection, CAPCD)网络。受活动轮廓模型的启发,将细胞检测任务视为轮廓回归问题。该网络融合了传统 Snake 算法的思想,首先利用基于中心距离热力图编码的初始轮廓构建模型(Initial Contour Building Model, ICBM)获取细胞的初始目标框,然后设计了轮廓偏移预测网络(Contour Offset Prediction Network, COPN)来迭代回归细胞轮廓,引入轮廓注意力模块,使模型在轮廓变形过程中专注回归非细胞轮廓点。在模型训练过程中,为了使模型关注细胞相邻轮廓点,提出一种轮廓点监督的偏移预测损失函数来训练模型。实验结果表明,本章提出的算法能有效提高细胞检测的准确度,并精确捕捉细胞的轮廓信息,为连续帧间的细胞跟踪提供了坚实的基础。

3.1 轮廓分析相关理论

3.1.1 传统 Snake 算法

Snake 算法^[67],又称为活动轮廓模型(Active Contour Model),旨在识别和跟踪图像中的对象轮廓。Snake 算法的核心思想是使用一组经过优化的控制点(称为“蛇”)来逼近目标对象的边界。这些控制点构成了一个轮廓曲线,能够在图像中移动并适应目标对象的形状,模型通过最小化能量目标函数控制参数曲线变形。如图 3.1 所示,随着迭代次数的增加,轮廓曲线在内部能量和外部能量的共同约束下逐渐逼近于目标边缘,最后在目标边界处像素梯度最大位置处停止运动,得到较为准确的目标物体的轮廓。




图 3.1 Snake 算法分割过程示意图

Fig 3.1 Schematic diagram of the segmentation process of the Snake algorithm

在简单的 Snake 模型中,可以用一组 n 个点 $v_i (i = 0, \dots, n - 1)$ 表示, v_i 代表图像中控制点的坐标,这些控制点通过参数 s 在曲线上插值,形成一个连续的曲线 $v(s)$ 。在控制点上定义能量函数如式(3-1)所示,主要包括内部能量项 E_{internal} 和基于边缘的外部能量项 E_{external} ,调节 Snake 模型的变形。外部能量项通常是由图像引起的力 E_{image} 和人为施加的约束力 E_{con} 的组合,以控制轮廓适应图像。

$$E_{\text{snake}} = \int_0^1 \left(E_{\text{internal}}(\mathbf{v}(s)) + E_{\text{image}}(\mathbf{v}(s)) + E_{\text{con}}(\mathbf{v}(s)) \right) ds \quad (3-1)$$

内部能量项 E_{internal} 主要用于保持 Snake 模型的平滑性和连续性。它通常包括两个部分：弯曲能量和张力能量，这些能量项通常与曲线的导数有关，如式(3-2)所示：

$$E_{\text{internal}} = \int (\alpha(s)|\mathbf{v}'(s)|^2 + \beta(s)|\mathbf{v}''(s)|^2) ds \quad (3-2)$$

其中， $\alpha(s)$ 和 $\beta(s)$ 分别表示控制曲线的张力和弯曲。

外部能量项中由图像引起的力 E_{image} 主要关注图像的线条、边缘或其他显著特征，如式(3-3)所示：

$$E_{\text{image}} = w_{\text{edge}}E_{\text{edge}} + w_{\text{line}}E_{\text{line}} + w_{\text{term}}E_{\text{term}} \quad (3-3)$$

其中， E_{edge} 通过寻找图像的梯度最大值来定义，即识别边缘的位置； E_{line} 可以帮助模型沿着线条移动，类似于 E_{edge} ，但是专门针对图像中的线性特征； E_{term} 则可以帮助模型定位到图像中的特定点或显著特征上。

外部能量项中人为施加的约束力 E_{con} 的目的是在 Snake 模型的演化过程中施加额外的控制和引导，以确保模型的行为符合特定的应用需求。一些常见的约束力包括位置约束、距离约束、角度约束和交互式约束。

3.1.2 扩张圆形卷积

考虑到细胞的形态主要呈圆形，本研究算法采用轮廓表示物体形状。具体实施中，采用一组环形排列、首尾衔接的点集。因此，在执行卷积运算时，本文选择使用扩张圆形卷积。扩张圆形卷积(Dilated Circular Convolution)^[68-70]是一种特殊类型的卷积，它结合了扩张卷积(Dilated Convolution)和圆形卷积(Circular Convolution)的概念，可以在保持边界点周期性的同时，有效地捕获和分析目标的局部和全局特征。如图 3.2 所示，在相同参数量和计算量下，传统卷积的卷积核为 3×3 ，而当扩张卷积的扩张率等于 2 时，感受野可以扩张到 5×5 。通过增加卷积核的扩张率，扩张卷积可以获得不同尺度的上下文信息，由于不需要引入额外的参数，因此计算量也会相应地降低。




图 3.2 卷积对比示意图：(a) 3×3 普通卷积，(b) 扩张率为 2 的 3×3 扩张卷积

Fig 3.2 Schematic comparison of convolutions: (a) 3×3 normal convolution, (b) 3×3 dilated convolution with dilation of 2

圆形卷积是周期卷积的一种特例，是两个周期相同的周期函数的卷积，多数应用于离散信号。在一维信号中的表示如式(3-4)所示：

$$h[n] * x_N[n] \triangleq \sum_{m=-\infty}^{\infty} h[m] \cdot x_N[n - m] \quad (3-4)$$

其中， h 代表卷积核， x_N 代表输入信号， $*$ 代表标准卷积。

本研究提取目标物体轮廓的特征点，考虑到物体轮廓点间的离散关系，采用圆形卷积而非传统的二维卷积进行特征计算。这种方法能够更好地适应点之间的离散性，并有效保留物体轮廓的拓扑结构。对于图像中的轮廓点，将轮廓顶点视为一个离散的一维信号，记为 $f: \mathbb{Z} \rightarrow \mathbb{R}^D$ ，将它拓展为一组周期信号，轮廓特征采用圆形卷积计算其周期特征，具体计算公式如式(3-5)、式(3-6)所示：

$$(f_N)_i \triangleq \sum_{j=-\infty}^{\infty} f_{i-jN} \quad (3-5)$$

$$(f_N * p)_i = \sum_{j=-r}^r (f_N)_{i+j} p_j \quad (3-6)$$

其中， $p: [-r, r] \rightarrow \mathbb{R}^D$ 是一个可学习的卷积核函数。

而扩张圆形卷积则结合了上述两种卷积的特点，它在应用卷积核时引入了扩张间隔，同时采用圆形卷积计算轮廓的周期特征，如图 3.3 所示，其中深蓝色点为原始输入轮廓，红色和白色点代表卷积核，白色点的值为 0，绿色为圆形卷积后的输出结果。通过增加卷积核的扩张系数，扩张圆形卷积可以获得不同尺度的感受野。




图 3.3 扩张圆形卷积示意图

Fig 3.3 Schematic diagram of dilated circular convolution

3.2 基于轮廓注意力的 CAPCD 网络

本文采用渐进式分割策略，作为 CAPCD 网络的细胞检测流程，如图 3.4 所示，主要分为两个阶段：首先构建初始轮廓，然后迭代预测轮廓偏移，最终实现细胞实例的精确分割。整个网络可以分为两个阶段。

第一阶段：通过 ICBM 网络获取细胞的初始目标框。ICBM 的核心网络架构采用深层聚合网络(Deep Layer Aggregation-34, DLA34)^[65]，能够捕获目标的关键信息，包括目标热力图特征、边界框尺寸和中心偏移量，从而为每个目标构建初始轮廓框。

第二阶段：通过 COPN 网络进一步细化细胞轮廓。具体来说，首先将第一阶段得到的细胞初始目标框输入到 COPN 网络中，识别得到目标的四个极值点^[71]，并基于此构建八边形轮廓框。然后对轮廓框采样，生成 N 个轮廓点，并将这些点再次输入 COPN 网络中进行细胞边缘的偏移预测。最后使用水平集方法对轮廓进行微调，优化轮廓分割的结果。




图 3.4 CAPCD 网络框架图

Fig 3.4 Framework diagram of CAPCD

如图 3.5 所示，是细胞轮廓迭代的具体流程，网络通过预测轮廓边缘点，并将这些点连接起来形成多边形，精确地描绘出物体的边缘轮廓。首先通过 ICBM 网络生成用于构建菱形轮廓的初始目标框，考虑到活动轮廓模型需要精确的初始轮廓，本文选择将初始目标框变形为八边形轮廓框^[71]。这个八边形轮廓框由目标的四个极值点组成，分别是极上、极下、极左、极右的四个点，记为 $\{x_i^{\text{ext}}|i=1,2,3,4\}$ 。接下来，为了形成基础轮廓，从 ICBM 网络检测到的初始目标框中，取四条边的中点作为顶点，记为 $\{x_i^{\text{mid}}|i=1,2,3,4\}$ ，这些中点连接起来形成一个菱形轮廓，并在轮廓上均匀采样 40 个点。最后将这个轮廓点集作为 COPN 网络的输入，输出从每个中点 x_i^{mid} 到相应极值点 x_i^{ext} 的偏移量 Δx_i ，如式 (3-7)所示：

$$x_i^{\text{ext}} = x_i^{\text{mid}} + \Delta x_i \quad (3-7)$$

然后通过基于极值点生成四条线段并连接端点来构造八边形。具体来说，四个极值点定义了一个新的边界框，每一个极值点都沿着边界框往两端延伸 1/4 的边界长度，再

将四条线段的端点相接，就构成了八边形轮廓框。这个八边形轮廓框尽可能地将物体包围在内。

类似的，再对八边形轮廓框采样 N 点，经实验验证，采样点 N 的最佳数量为 128^[72]，用 $\{x_i^{\text{oct}} | i = 1, 2, 3, \dots, N, N = 128\}$ 表示，此时能在不过度增加网络计算量的情况下，有效覆盖大部分目标的轮廓。将得到的轮廓点集输入 COPN 网络，输出得到轮廓点偏移量 $\Delta x_i'$ ，如式(3-8)所示：

$$x_i^{\text{oct}'} = x_i^{\text{oct}} + \Delta x_i \quad (3-8)$$




图 3.5 细胞轮廓迭代流程图

Fig 3.5 Iterative flowchart for cell contour

然而结果表明只有一次轮廓偏移预测是不可靠的，特别是对于距离真实轮廓较远的预测点，因此本文考虑以多次迭代优化^[73]的方式来提高模型性能。具体来说，对于每次预测的 N 个轮廓偏移量，通过顶点方向将偏移量添加到其顶点坐标来变形该轮廓，变形后的轮廓再作为下一次迭代预测的输入。

3.3 基于中心距离热力图编码的初始轮廓构建模型

目标检测的核心目标是在图像中准确识别和定位每一个实例，为它们标注位置信息和类别标签，这对于后续的实例分割过程至关重要。本研究提出的基于中心距离热力图编码的 ICBM 网络采用无锚框检测方法 CenterNet 作为基础网络，利用热力图捕获物体中心点及其位置信息。

如图 3.6 所示，ICBM 网络采用 DLA34 网络作为编解码器，输出 3 个检测头，分别是热力图($N \times W \times H$)、热力图对应的宽高值($1 \times W \times H$)和热力图对应的中心点偏移($1 \times W \times H$)，其中 N 代表输入图像中目标的数量， W 和 H 为输入图像的宽和高。加入中心点偏移量分支是为了修正热力图回归目标中心点只能为整数的误差。然后，从热力图中识别出 k 个高斯峰值点作为目标中心点。对于每个中心点，根据相应的宽高值矩阵和中心点偏移矩阵确定其宽高和中心偏移量，进而构建候选目标框。最终，以热力图中的

评分作为分类依据，当评分超过预定阈值时，将该目标框作为最终输出。




图 3.6 基于中心距离热力图编码的 ICBM 网络示意图

Fig 3.6 Schematic of ICBM network based on centre distance heat map coding

热力图在网络对于目标的定位与识别过程中起着重要作用，特别是在无锚框检测架构中。生成热力图首先需要根据目标的大小确定合适的高斯核半径，然后为每个目标根据其类别和中心位置在相应的热力图上应用这一高斯核，创建二维高斯分布图。通过优化热力图的损失，训练卷积神经网络识别这些分布。将目标的中心点映射为热力图上的局部最大值，便能通过搜索热力图的峰值来精确地定位目标中心。

然后是针对每个目标，依据其类别及中心位置，在相应类别的热力图上生成高斯核半径对应的二维高斯分布图。通过使热力图的损失最小为目标，训练卷积神经网络，使其学习热力图的具体分布。这个过程实质上是将对象的中心点位置转化为热力图上的局部最大值，从而可以通过寻找热力图上的峰值来定位对象的中心点。

CenterNet 采用的标准圆形高斯核函数对所有方向均等处理，假定目标在各个方向上的扩散均匀，对于均匀分布的对象定位和识别相对适用，但此方法并不适合形状大小不一的细胞目标。为了解决这一问题，本文采用一种基于中心距离的热力图编码方法。此方法根据目标框的尺度信息调整高斯分布，仅依据目标框中心点来确定高斯核函数，同时还考虑了热力图中心点周围目标框的尺度信息，以此生成更多的监督特征。

在训练过程中，首先需要确定关键点的实际位置 $p \in \mathbb{R}^2$ ，为了适应特征输出尺度的 R 倍降采样，计算出一个等效位置 $\tilde{p} \in \left[\frac{p}{R} \right]$ ，然后在热力图上使用二维高斯核函数标记这一等效位置。二维高斯核函数 Y_{cen} 的计算公式如式(3-9)所示：

$$Y_{\text{cen}} = \exp \left[-\frac{(x - \tilde{p}_x)^2}{\left(\frac{a}{3}\right)^2} - \frac{(y - \tilde{p}_y)^2}{\left(\frac{b}{3}\right)^2} \right] \quad (3-9)$$

其中， (x, y) 为下采样后该点的坐标， $(\tilde{p}_x, \tilde{p}_y)$ 为下采样后的目标中心点坐标， a 和 b 为椭圆的长短半轴，满足 $a/b = W/H$ 的关系。

图 3.7 描述了圆形和椭圆形两种约束，包括三种目标重叠的情况：预测目标框包围真实目标框、两者部分重叠以及真实目标框包围预测目标框，其中黄色框表示真实目标框，绿色框表示预测目标框。本文设定的预测框与真实框重叠的策略通过椭圆形的约束来实现，其中椭圆的长短轴由真实目标框的宽度 W 和高度 H 决定。




图 3.7 目标框重叠关系: (a) 预测框包围真实框, (b) 两者部分重叠, (c) 真实框包围预测框

Fig 3.7 Target frame overlap relationship: (a) prediction frame surrounds the true frame, (b) both partially overlap, (c) true frame surrounds prediction frame

假设从椭圆中心到椭圆上任意点的连线与水平轴的夹角为 θ 。定义满足 $\tan\theta = W/H$ 的连线长度为 r 。根据椭圆的定义, r 可以从式(3-10)计算得出:

$$r = \frac{\sqrt{2(a^2 + b^2)}}{2} \quad (3-10)$$

此时图 3.7 中三种临界情况的高斯核半径 r_1 、 r_2 和 r_3 可由式(3-11)-式(3-13)确定:

$$r_1 = \frac{(1 - \sqrt{\text{IoU}})\sqrt{W^2 + H^2}}{2\sqrt{\text{IoU}}} \quad (3-11)$$

$$r_2 = \frac{(1 - \sqrt{\text{IoU}})\sqrt{W^2 + H^2}}{2} \quad (3-12)$$

$$r_3 = \left(1 - \sqrt{\frac{2\text{IoU}}{1 + \text{IoU}}}\right)\sqrt{W^2 + H^2} \quad (3-13)$$

将 $a/b = W/H$ 分别代入式(3-11)-式(3-13)可分别得式(3-14)-式(3-16), 并根据式(3-17)求得 a 和 b :

$$\begin{bmatrix} a_1 \\ b_1 \end{bmatrix} = \frac{\sqrt{2}(1 - \sqrt{\text{IoU}})}{2\sqrt{\text{IoU}}} \begin{bmatrix} W \\ H \end{bmatrix} \quad (3-14)$$

$$\begin{bmatrix} a_2 \\ b_2 \end{bmatrix} = \frac{\sqrt{2}(1 - \sqrt{\text{IoU}})}{2} \begin{bmatrix} W \\ H \end{bmatrix} \quad (3-15)$$

$$\begin{bmatrix} a_3 \\ b_3 \end{bmatrix} = \left(\sqrt{2} - 2\sqrt{\frac{\text{IoU}}{1 + \text{IoU}}}\right) \begin{bmatrix} W \\ H \end{bmatrix} \quad (3-16)$$

$$\begin{bmatrix} a \\ b \end{bmatrix} = \begin{bmatrix} \min(a_1, a_2, a_3) \\ \min(b_1, b_2, b_3) \end{bmatrix} \quad (3-17)$$

从图 3.8 可见, 根据标准圆形高斯核生成的热力图在训练网络时, 对于宽度和高度不等的物体在水平和垂直方向上扩散是均匀的。在真实目标框外生成了负样本, 导致最

终网络损失较大。而本节采用的基于中心距离编码生成的热力图，更贴合目标物的实际外观，有效缩小了热力图非零点的分布范围，并过滤掉了不必要的负样本。这样的编码策略在形式上更加合理，不仅增强了目标检测模型对于复杂形态目标的适应性，也提升了识别和定位的精度，适用于处理不规则形状的对象，如细胞等。




图 3.8 高斯核生成热力图对比示意图

Fig 3.8 Schematic comparison of heatmap generated by Gaussian kernel

3.4 基于轮廓注意力的轮廓偏移预测网络

得到初始轮廓框以后，本实验采用基于轮廓注意力的 COPN 网络进一步细化细胞轮廓。COPN 网络主要由轮廓特征提取模块，轮廓注意力模块和预测模块三个部分组成。如图 3.9 所示，轮廓特征提取模块通过多层扩张圆形卷积和残差连接获取轮廓特征。轮廓注意力模块通过注意力加权，增强模型对目标边缘外顶点的关注。预测模块融合所有层的多尺度信息，通过最大池化和 1×1 卷积操作精细化顶点位置预测。




图 3.9 基于轮廓注意力的 COPN 网络框架图

Fig 3.9 Framework diagram of COPN network based on Contour Attention

3.4.1 轮廓特征提取模块

如图 3.10 所示，轮廓特性提取模块包含 8 个扩张圆形卷积层(Dilated Circular Convolution, Dilated CirConv2d)，每层后接批归一化(Batch Normalization, BN)和 ReLU 激

活函数。所有层间采用残差连接，这种连接方式有助于信息的流动和梯度的反向传播，从而防止训练过程中的性能退化。为了整合不同层次的信息并提高特征表示能力，模块输出不仅包括层间信息的累加，还有通过 1×1 卷积进行的特征融合。此外，该模块的扩张率遵循 U 形结构(1, 1, 2, 4, 4, 2, 1, 1)，这种设计旨在通过先增大后减小的扩张率变化，增强模型对不同尺寸目标的分割能力，特别是改善对小目标的分割表现。通过这种结构设计，模块能够有效整合不同尺度的特征，提升轮廓特性提取的性能。




图 3.10 轮廓特征提取模块

Fig 3.10 Contour feature extraction module

实验发现扩张率为 4 的红色圆形卷积模块主要依赖于扩张率为 2 的黄色卷积模块的输入，而扩张率为 1 的蓝色圆形卷积模块提供的信息相对较少。由于感受野偏大，导致了网络对小目标的分割精度不足。同样，最后的蓝色圆形卷积模块经常缺乏高扩张率模块的信息，影响了模型感受全局信息的能力。为解决上述问题，本文引入了两个额外的跳跃连接，促进不同层间信息的有效流动和融合，减少过拟合的风险，并增强了模型在小目标分割和全局信息整合方面的性能。

3.4.2 尺度平移不变的轮廓归一化方法

为了实现轮廓变形的平移不变性，在 Deep Snake^[72]中是通过从每个顶点坐标中减去轮廓上所有顶点的最小值来归一化轮廓，以实现平移不变的轮廓变形。然而，这种平移不变的归一化不足以实现稳定的学习，因为细胞的形态尺寸差异会严重影响回归偏移的范围，从而增加了轮廓特征提取模块学习的复杂度。

为了解决这个问题，本文提出了一种同时考虑尺度和平移不变性的归一化方法，降低目标物体尺寸差异对学习过程的影响，从而提高特征提取模块的效率和准确性。具体来说，在轮廓特征提取之前，对每个顶点 (x_i, y_i) 进行归一化处理，如式(3-18)所示：

$$x_i = \frac{x_i - x_{\min}}{x_{\max} - x_{\min}}, y_i = \frac{y_i - y_{\min}}{y_{\max} - y_{\min}} \quad (3-18)$$

其中, $(x_{\min}, y_{\min})$ 和 $(x_{\max}, y_{\max})$ 分别代表轮廓上所有顶点的最小和最大坐标值。

通过这种方法, 顶点坐标被限定在 $[0,1]$ 范围内, 以保持预测偏移量的一致性。预测的偏移量通过 $\tanh$ 函数进一步处理, 确保输出值在合理范围内。该归一化策略主要借鉴了 RoI Align(Region of Interest Align)^[37]的思想, 即将不同大小的对象映射到固定大小的特征图上, 从而使模型能够集中于描述对象的形状, 而不是其在图像中的尺寸或位置。模型输出的偏移量 $\{(\Delta x_i, \Delta y_i)\}_{i=1}^K$ 用于更新顶点坐标 $(x_i^{\text{new}}, y_i^{\text{new}})$, 如式(3-19)、式(3-20)所示:

$$\{(\Delta x_i, \Delta y_i)\}_{i=1}^K = \tanh(\text{COPN}(\{\mathcal{F}(x_i, y_i)\}_{i=1}^K)) \quad (3-19)$$

$$x_i^{\text{new}} = x_i^{\text{old}} + W * \Delta x_i, y_i^{\text{new}} = y_i^{\text{old}} + H * \Delta y_i \quad (3-20)$$

其中 W 和 H 代表目标的宽度和高度。

3.4.3 轮廓注意力模块

为了提高细胞检测和跟踪的准确性, 本文对原有轮廓回归模型进行了改进, 引入了轮廓注意力(Contour Attention, CA)模块。以前的模型是训练回归接近物体轮廓的所有顶点, 包括那些靠近物体边界的顶点。但是, 这一设定要求模型不仅要回归轮廓上的顶点, 也要处理轮廓外的顶点, 二者在动态上的差异显著, 从而降低了学习效率。鉴于此, 本文提出将轮廓回归过程拆分为两个步骤, 首先是轮廓偏移量的预测回归, 然后是应用一个注意力模块, 该模块识别出所有顶点中的边界外点, 并迫使模型在轮廓变形过程中专注于这些顶点的回归, 而忽略其他顶点。

本研究提出了一个简单有效的 CA 模块, 整合了物体的边界信息, 以增强模块在判断顶点是否已经接触到物体边界时的能力。如图 3.9 所示, 在轮廓特征提取模块后, 先通过应用 1×1 卷积和 Sigmoid 激活函数对特征图进行类别不可知的轮廓预测监督, 然后将所得轮廓边缘图通过多层卷积层进一步处理, 这些卷积层之间穿插有 GroupNorm 和 ReLU, 最终通过一个 Sigmoid 激活函数产生一个图像级别的注意力图 $F_{att}(x_i, y_i)$, F_{att} 可视化示意如图 3.11(b)所示。基于此注意力图, 对每个像素的调制系数进行采样, 并将其与原始预测的偏移量 $(\Delta x_i, \Delta y_i)$ 相乘, 如式(3-21)所示。 F_{att} 迫使模型在轮廓变形过程中专注于边界外顶点的回归, 如图 3.11(c)所示, 只有距离目标轮廓较远的顶点才会偏移变形, 而轮廓上的顶点则不会受到影响。

$$[\Delta x'_i, \Delta y'_i] = F_{att}(x_i, y_i) \times [\Delta x_i, \Delta y_i] \quad (3-21)$$




图 3.11 CA 模块示意图

Fig 3.11 Schematic diagram of the CA module

3.4.4 水平集后处理

水平集(Level Set)^[74, 75]作为一种传统的数学方法, 常用于处理轮廓演化和形态变化问题。本文采用水平集方法作为 COPN 模型的后处理步骤, 用以平滑优化细胞轮廓。水平集函数由能量部分和正则化项组成, 如式(3-22)所示:

$$\varepsilon(\phi) = \mu R_p(\phi) + \varepsilon_{\text{ext}}(\phi) \quad (3-22)$$

其中, $\varepsilon_{\text{ext}}(\phi)$ 项表示外部能量项, 用于促使轮廓与目标轮廓对齐; $R_p(\phi)$ 是对水平集导数的惩罚项, 以维持函数的平滑性, 其定义如式(3-23)所示:

$$R_p(\phi) = \int_{\Omega} p(|\nabla\phi|)dx \quad (3-23)$$

其中, ϕ 表示轮廓线, 由一组值为 0 的点集表示。

由于远离轮廓的梯度幅度基本趋于 0, 因此在演化过程中, 只需要针对轮廓附近的点进行更新, 而无需处理整个图像的点, 这种有选择的更新策略, 可以有效提升水平集函数的分割性能。将水平集函数应用于模型的后处理阶段, 可以有效地细化和平滑细胞边缘, 提高整体的细胞分割精度。

3.4.5 混合损失函数

COPN 网络的损失函数主要由三部分组成: 检测损失 L_{det} 、偏移预测损失 L_{offset} 、边界损失 L_{edge} , 其中 α 和 β 根据经验^[72]分别设置为 10 和 1, 如式(3-24)所示。

$$\text{Loss} = L_{\text{det}} + \alpha L_{\text{offset}} + \beta L_{\text{edge}} \quad (3-24)$$

检测损失 L_{det} 主要包含目标分类损失 L_{ct} 和回归定位损失 L_{wh} , 本文分别采用 Focal Loss 和 Smooth L1 损失函数用于模型训练, 如式(3-25)-式(3-27)所示:

$$L_{\text{det}} = L_{\text{ct}} + L_{\text{wh}} \quad (3-25)$$

$$L_{\text{ct}} = -(1 - p_t)^{\gamma} \log(p_t) \quad (3-26)$$

$$L_{\text{wh}} = \ell_1(x) = \begin{cases} 0.5 \cdot x^2 & \text{if } |x| < 1 \\ |x| - 0.5 & \text{otherwise} \end{cases} \quad (3-27)$$

对于偏移预测损失 L_{offset} , Deep Snake 使用 Smooth L1 损失函数来训练轮廓点的偏移量, 如式(3-28)所示:

$$L_{\text{offset}} = \frac{1}{N} \sum_{i=1}^N \ell_1(\tilde{x}_i - x_i^{\text{gt}}) \quad (3-28)$$

其中, $\tilde{x}_i$ 和 x_i^{gt} 分别表示归一化后的预测和真实轮廓点。

但在对复杂轮廓进行回归时, 这种损失会导致在小范围内多个连续的轮廓点之间经常发生对应交错。为了解决这一问题, 本研究提出了一个新的偏移预测损失 L_{dis} , 旨在使初步识别的轮廓点回归到其附近的最近真实轮廓点, 从而有效减少对应交集。受倒角距离损失^[76, 77]的启发, L_{dis} 的定义如式(3-29)所示:

$$L_{\text{dis}} = L_{\text{offset}} = \frac{1}{N} \sum_{i=1}^N \ell_1 \left(\min_{v_j \in \mathcal{X}_{(i-q, i+q)}^{\text{gt}}} \|\tilde{x}_i - v_j^{\text{gt}}\|_2 \right) \quad (3-29)$$

其中, $v_j \in \mathcal{X}_{(i-q, i+q)}^{\text{gt}}$ 为 x_i^{gt} 相邻的 $2q + 1$ 个轮廓点, q 值根据第 3.5.3 节的实验设为 2。这

种方法通过在包含多个点的窗口内选择最近点进行回归，而非简单地与单一最近点匹配，提高了回归的精确度和模型对复杂轮廓的适应性。

边界损失 L_{edge} 采用 Dice 损失函数，用于监督轮廓注意力变形中的边界预测，具体公式如式(3-30)所示：

$$L_{\text{edge}} = \frac{2 \times |X \cap Y|}{|X| + |Y|} \quad (3-30)$$

其中， X 代表预测的轮廓边界点集， Y 代表真实的轮廓边界点集。

3.5 实验设置与结果分析

3.5.1 实验设置

本文的实验环境配置如下：操作系统使用 Windows 11，处理器为 AMD Ryzen™ 5 3600X，显卡配置为搭载 8GB 显存的 GEFORCE GTX 2080。实验中模型的构建是基于 CUDA10.1 版本的 Pytorch1.4 开源深度学习框架进行的，采用 Python3.7 作为主要的编程语言。

网络参数的设定对于算法模型训练的效果具有重要影响。若不进行超参数的适当调整，可能会导致模型在训练过程中遇到不收敛或仅部分收敛的问题。因此，在开始训练之前，对模型的超参数进行预设是必要的。本章实验中主要调整的超参数包括批处理大小(Batch Size)、初始学习率以及总训练迭代次数(Epochs)等。

鉴于计算机的显存限制，在训练过程中将 Batch Size 设置为 4，意味着每次向深度学习网络模型输入的图像数量为 4 张。Epochs 设定为 300。为了提高训练效率，选择了具备自适应学习率调整机制的 Adam 优化器。此外，初始学习率设定为 0.001，并且调整了优化器的 beta1 和 beta2 参数为 0.9 和 0.999。

3.5.2 评价指标

为了评估本章提出的 CAPCD 网络的有效性，本研究采用平均精度(Average Precision, AP)作为实验评估的主要标准。AP 值通过绘制 Precision-Recall 曲线并计算该曲线下面积得出，反映了模型在不同置信度阈值下的性能，精确率(Precision)、召回率(Recall)和 AP 的计算公式如式(3-31)-式(3-33)所示：

$$P_n = \frac{TP}{TP + FP} \quad (3-31)$$

$$R_n = \frac{TP}{TP + FN} \quad (3-32)$$

$$AP = \sum_n (R_n - R_{n-1})P_n \quad (3-33)$$

其中，TP(True Positives)是正确预测的细胞像素点数，FP(False Positives)是错误标记为细胞的非细胞像素点数，FN(False Negatives)是未被检测到的实际细胞像素点数。 P_n 和 R_n 分别代表第 n 个置信度阈值下的 Precision 和 Recall。

AP 通过综合考虑在各个置信度阈值下的 Precision 和 Recall 值，以召回率的变化为

基础进行计算得到。通过将 IoU 阈值设定在不同的标准,如 0.5(AP_{50})和 0.7(AP_{70}),并对 IoU 阈值从 0.5 到 0.95 以 0.05 为间隔的所有 AP 值取平均,便能得到一个综合评估模型性能的 AP 指标。此外,本文根据细胞在图像中所占像素的数量将其分为三类:小型细胞、中型细胞和大型细胞,分别指所占像素少于 32^2 、 32^2 至 96^2 和大于 96^2 的细胞,分别通过 AP_{small} 、 AP_{medium} 、 AP_{large} 来反映其 AP 值。

3.5.3 实验结果分析

为了验证本研究提出的基于轮廓注意力的 CAPCD 算法在细胞实例分割应用中的有效性,本文包含以下几个方面的实验:在含不同浓度过氧化氢的 MCF-7 肿瘤细胞数据集上,进行对比实验;各模块的消融实验;设计实验确定 COPN 网络的最佳迭代次数,以及偏移预测损失函数 L_{dis} 的最佳采样间隔点;在 MCF-7 和 Fluo-C2DL-Huh7 细胞数据集上与当前的 SOTA 实例分割算法进行对比实验。

本文在六组含不同过氧化氢浓度的 MCF-7 肿瘤细胞数据集上进行检测分割实验,每组实验包括了 24 小时内的 144 帧图像,并且从中选取了第 1 帧、第 50 帧和第 100 帧的图像进行可视化分析。实验结果如表 3.1 所示,可视化结果如图 3.12 所示。可以看到每一组细胞的 AP 指标都较好,由于该数据集的细胞类型多为中型细胞,因此中型细胞分割效果最好, AP_{medium} 较高。在 250 μM 的过氧化氢浓度组中, AP 值最高,有着最佳的检测和分割性能。而在 0 μM 和 1000 μM 的过氧化氢浓度组中, AP 值较低,分析原因是较低浓度组的细胞过于密集,导致粘连现象增多,模型难以有效检测分割;而在较高浓度组,由于过氧化氢浓度过高,大部分细胞体积缩小并逐渐死亡,导致网络在降采样过程中难以提取到足够的特征,从而影响了检测效果。

表 3.1 基于含过氧化氢 MCF-7 肿瘤细胞数据集的分割结果

Table 3.1 Segmentation results based on the hydrogen peroxide-containing MCF-7 tumour cells dataset

过氧化氢浓度	$AP(\%) \uparrow$	$AP_{50}(\%) \uparrow$	$AP_{small}(\%) \uparrow$	$AP_{medium}(\%) \uparrow$	$AP_{large}(\%) \uparrow$
0 μM	45.3	84.7	23.5	45.9	39.2
50 μM	47.9	88.4	27.1	47.5	42.3
100 μM	48.2	87.3	26.2	48.9	41.8
250 μM	48.3	88.7	27.8	49.1	45.8
500 μM	48.2	88.0	26.2	48.9	43.9
1000 μM	45.3	83.3	24.4	47.3	35.4




图 3.12 不同浓度过氧化氢 MCF-7 肿瘤细胞数据集分割示意图

Fig 3.12 Schematic of the segmentation of the MCF-7 tumour cells dataset with different concentrations of hydrogen peroxide

为了深入了解本章所用各模块的有效性, 本文以 Deep Snake 算法^[72]作为基线 (Baseline), 并通过消融实验在含 250 μM 过氧化氢浓度的 MCF-7 肿瘤细胞数据集上研究中心距离热力图编码(Cen-dis Heatmap)、CA 模块、水平集后处理方法和轮廓偏移损失函数 L_{dis} 的有效性, 在未使用 L_{dis} 的消融实验部分, 采用 Smooth L1 损失函数作为替代。

实验结果如表 3.2 所示,可以看出引入中心距离热力图编码和 CA 模块对于模型性能提升明显,其中 CA 模块的贡献相比中心距离热力图编码略大。中心距离热力图编码主要改善的是初始轮廓定位,而 CA 模块对于轮廓回归的监督作用更为显著。此外,虽然水平集后处理和基于倒角距离的轮廓偏移损失函数 L_{dis} 对模型性能的提升虽然不如中心距离热力图编码和 CA 模块明显,但也都对模型在精确分割细胞轮廓方面起到了促进作用。

表 3.2 算法模块消融实验结果对比

Table 3.2 Comparison of the results of the algorithm module ablation experiments

Study	Baseline	Cen-dis Heatmap	CA	Level Set	L_{dis}	AP(%)↑	AP ₅₀ (%)↑
1	✓					46.3	84.9
2	✓	✓				46.7	85.2
3	✓	✓	✓			48.0	86.8
4	✓	✓	✓	✓		48.1	87.2
5	✓	✓	✓	✓	✓	48.2	87.3

本文提出的基于轮廓注意力的 COPN 网络采用推理迭代的训练方法来优化模型性能。为了探究迭代次数对 COPN 网络性能的影响,本文在含 250 μM 过氧化氢浓度的 MCF-7 肿瘤细胞数据集上进行对比实验,实验结果如表 3.3 所示。实验结果表明当迭代次数为 3 时,网络达到了最佳性能,分割精度最高。相比之下,迭代次数过多或过少都会导致各项 AP 值降低。从图 3.13 可以看到,在网络训练迭代到第三轮时轮廓回归效果最好。因此过多的迭代次数并不会带来性能的持续提升,反而可能因网络难以学习到更有效的特征而导致性能下降。因此本研究确定 COPN 网络的迭代次数为 3。




图 3.13 COPN 网络推理迭代次数对比

Fig 3.13 Comparison of the number of iterations of COPN network reasoning

表 3.3 COPN 网络推理迭代次数实验结果对比

Table 3.3 Comparison of experimental results on the number of iterations of COPN network reasoning

Iters	AP(%)↑	AP ₅₀ (%)↑	AP _{small} (%)↑	AP _{medium} (%)↑	AP _{large} (%)↑
1	46.3	85.7	24.9	47.2	39.8
2	48.0	86.8	25.9	48.5	41.4
3	48.2	87.3	26.2	48.9	41.8
4	47.9	86.7	25.9	48.9	41.5
5	47.0	85.9	24.8	47.5	40.1

为了确定轮廓偏移预测损失函数 L_{dis} 的采样间隔点超参数 q ，本文通过设置不同的 q 来评估模型的性能，实验结果如表 3.4 所示。可以看到随着 k 值的增加，模型的各项 AP 值先是稳定增加，但当 q 达到 3 时，各项 AP 值均开始呈下降趋势。虽然较大的 q 意味着在计算轮廓点的偏移损失时考虑了更多周围的轮廓点，但这也会导致轮廓点的偏移预测不准确，进而降低了模型的整体性能。因此本文最终选择将 q 设置为 2。

表 3.4 偏移预测损失函数 L_{dis} 采样间隔点 q 实验结果对比Table 3.4 Comparison of experimental results of offset prediction loss function L_{dis} sampling interval point q

k	AP(%)↑	AP ₅₀ (%)↑	AP _{small} (%)↑	AP _{medium} (%)↑	AP _{large} (%)↑
0	48	86.1	13.8	46.8	40.5
1	47.6	84.7	25.4	47.1	37.1
2	48.2	87.3	26.2	48.9	41.8
3	46.3	84.2	23.7	45.9	35

本文还在含 250 μM 过氧化氢浓度的 MCF-7 肿瘤细胞数据集上对比了现阶段较为先进的网络模型，包括基于像素回归的 YOLACT^[27]、Mask R-CNN^[37]和 CenterMask^[78]，以及基于轮廓回归的 ExtremeNet^[71]、PolarMask^[79]和 Deep Snake^[72]，实验结果如表 3.5 所示。在基于轮廓的方法中，本章提出的细胞检测算法在 AP 和 AP₅₀上分别达到了 48.2% 和 87.3%，相较于 Deep Snake 分别提升了 1.9%和 2.4%，同时与基于像素回归的算法中性能最好的 CenterMask 相比，在 AP 和 AP₅₀上分别高出 0.6%和 1.4%。此外，在 AP_{small}、AP_{medium} 和 AP_{large} 这三个细分指标上均优于其他模型，表明了本章基于轮廓注意力的 CAPCD 网络的优越性和有效性。

表 3.5 不同模型实验结果对比

Table 3.5 Comparison of experimental results of different models

Models	AP(%)↑	AP ₅₀ (%)↑	AP _{small} (%)↑	AP _{medium} (%)↑	AP _{large} (%)↑
Pixel-based					
YOLACT ^[27]	34.2	72.8	22.5	35.6	34.3
Mask R-CNN ^[37]	38.2	80.4	25.9	39.2	38.4
CenterMask ^[78]	47.6	85.9	27.1	46.7	40.2
Contour-based					
ExtremeNet ^[71]	46.3	84.8	13.9	48.6	35.8
PolarMask ^[79]	43.8	83.5	22.6	45.9	37.4
Deep Snake ^[72]	46.3	84.9	25.5	47.1	40.5
Proposed Model	48.2	87.3	26.2	48.9	41.8

通过选取不同时刻的细胞图像并将本文算法与三种代表性算法——基于像素回归的 Mask R-CNN 和 CenterMask，以及基于轮廓回归的 Deep Snake 进行比较，结果如图 3.14 所示。对比结果可以发现，在基于像素的方法中，Mask R-CNN 和 CenterMask 常常因为细胞密集和相连，难以区分单独细胞，从而导致较多的漏检情况。尽管 CenterMask 引入了空间注意力引导的掩码分支来改善这一问题，但由于细胞边界内外的区分并不明显，这些基于像素的方法仍旧难以提取出有效的特征，漏检情况难以改善。而基于轮廓的 Deep Snake 方法在总体的分割效果上表现稍好，但是在细胞密集区域的分割效果依旧不理想，存在细胞漏检和边缘分割不准确的问题。




图 3.14 不同模型分割效果对比

Fig 3.14 Comparison of segmentation effect of different models

与这些方法相比,本文提出的基于轮廓注意力的 CAPCD 网络在细胞检测的全面性、细胞轮廓的清晰度和圆滑性,以及细胞整体结构与 Ground Truth 的接近度均表现出色。该方法通过设计渐进式分割网络,逐步细化细胞分割结果,能够更好地分割密集区域细胞,此外,引入轮廓注意力模块,有效地整合了轮廓信息与细化分割策略,不仅提高了分割精度,还增强了模型处理细胞密集区域性能,体现了模型在复杂场景下的适用性和有效性。

本文对几种网络模型在 DIC-C2DH-HeLa 公共数据集上进行了对比测试,包括基于像素回归的 YOLACT、Mask R-CNN 和 CenterMask,以及基于轮廓回归的 ExtremeNet、PolarMask 和 Deep Snake,实验结果如表 3.6 所示。结果表明本文提出的 CAPCD 网络取得了最优的性能,相比于 Deep Snake,在 AP 和 AP₅₀ 上分别提升了 2.0%和 1.7%,与 CenterMask 相比,这两个指标也分别提升了 0.8%和 1.6%。这些结果证明了本章提出的算法在细胞实例分割任务上的泛化性和优越性。

表 3.6 基于 DIC-C2DH-HeLa 数据集的不同模型分割结果对比

Table 3.6 Comparison of different model segmentation results based on DIC-C2DH-HeLa dataset

Models	AP(%)↑	AP ₅₀ (%)↑	AP _{small} (%)↑	AP _{medium} (%)↑	AP _{large} (%)↑
Pixel-based					
YOLACT	33.8	72.7	22.4	35.3	34.1
Mask R-CNN	37.9	80.1	25.2	38.8	38.0
CenterMask	47.0	85.3	25.2	46.1	39.7
Contour-based					
ExtremeNet	46.1	84.6	13.2	48.3	35.6
PolarMask	43.5	83.2	22.4	45.8	37.2
Deep Snake	45.8	84.6	25.1	46.7	40.2
Proposed Model	47.8	86.9	25.8	48.5	41.5

3.6 本章小结

本章主要提出了一种基于轮廓注意力的渐进式细胞检测网络 CAPCD,主要包括两个网络模块:ICBM 模型和 COPN 网络。ICBM 模型通过基于目标中心点距离的编码方式生成热力图,用于初步检测并定位细胞目标框;而 COPN 网络则利用轮廓注意力图进行细胞轮廓的精确回归。在实验部分,通过调节超参数确定了 COPN 网络的最佳迭代次数为 3,且在偏移预测损失函数 l_{dis} 中设置采样间隔点为 2,对比了提出的网络与其他模型的性能,验证轮廓注意力机制的有效性。结果表明本算法在自建的 MCF-7 肿瘤细胞数据集上的 AP 和 AP₅₀ 分别达到了 48.2%和 87.3%;在 DIC-C2DH-HeLa 公共数据集上分别达到 47.8%和 86.9%,能够精准检测分割大部分细胞轮廓。

第4章 基于混合特征自适应匹配的细胞跟踪算法

在 MOT 的数据关联阶段，一般采用基于 IoU 的运动特征、通过 ReID 提取的外观特征或是将这些特征加权融合，以构建代价矩阵^[23, 80-84]。尽管在一些简单场景下，单独使用 IoU 能够取得不错的效果，但当面对物体密集分布、运动不规则、或物体在被遮挡后再次出现等复杂情形时，跟踪效果便不够理想。此外，考虑到细胞内部形态结构的相似性，依靠 ReID 提取外观特征也不够有效。因此，选择合适的方法提取外观和运动特征，并通过设定权重融合特征是一种有效的策略。然而，精细调整权重参数不仅耗时而且直接应用在新数据集时往往不适用。鉴于此，本研究提出了基于混合特征自适应匹配的 HFM-Tracker 细胞跟踪算法，首先通过结合细胞形态特征(Cell Morphological Features, CMF)和混合运动特征(Mixed Motion Features, MMF)的自适应代价矩阵(Adaptive Cost Matrix, ACM)模块来关联细胞的运动轨迹；随后，采用卡尔曼滤波器根据细胞的历史状态和观测到的运动量预测其未来状态，以实现准确的轨迹跟踪。

4.1 多目标跟踪算法

4.1.1 DeepSORT 算法

DeepSORT 算法是一种经典的目标跟踪算法，在 SORT 算法的基础上引入了目标重识别(ReID)技术，减少了跟踪过程中 ID 切换频繁的现象，不过其核心依然是基于卡尔曼滤波预测算法和匈牙利匹配算法。算法利用卡尔曼滤波算法基于目标当前状态和动态模型预测目标在下一帧的状态，将预测状态与新一帧中的检测结果利用匈牙利算法进行高效匹配，最终实现跟踪。

卡尔曼滤波是一种利用运动特性来预测目标运动轨迹的算法。其核心思想在于通过不断迭代测量数据和预测模型，实现对系统状态的最优估计。该算法假定系统状态遵循线性变化，同时认为测量噪声和过程噪声均服从高斯分布。状态估计模型 $\mathbf{X}$ 可以表示为式(4-1)：

$$\mathbf{X} = [u, v, s, r, u', v', s']^T \quad (4-1)$$

其中， (u, v, s) 指的是当前帧的目标中心的水平坐标、垂直坐标、检测框面积， r 表示目标检测框的纵横比， (u', v', s') 为下一帧检测目标中心的水平坐标、垂直坐标、检测框面积。

算法主要分为预测和更新两个阶段。在预测阶段，算法利用先前状态的修正估计来预测当前状态。更新阶段则结合卡尔曼增益和新的观测数据来修正先前的预测，从而得到更精确的当前状态估计。通过这种迭代方式，算法能够不断地改进对系统状态的估计。

DeepSORT 算法采用匈牙利算法来处理分析代价矩阵，并采用了一种级联匹配策略，结合了目标位置的马氏距离和外观特征的余弦相似度两个关键度量。这种策略不仅考虑了目标的空间位置差异，还综合了目标的外观信息，增强了跟踪的准确性和鲁棒性。具

体来说, 马氏距离用于量化跟踪目标之间在空间位置上的相似度, 如式(4-2)所示, 余弦相似度用于评估目标的外观特征之间的相似性, 如式(4-3)所示, 最后代价矩阵 $c_{i,j}$ 结合上述两种距离, 如式(4-4)所示。

$$d^{(1)}(i, j) = (d_j - y_i)^T \mathbf{S}_i^{-1} (d_j - y_i) \quad (4-2)$$

$$d^{(2)}(i, j) = \min \{1 - r_j^T r_k^{(i)} \mid r_k^{(i)} \in \mathcal{R}_i\} \quad (4-3)$$

$$c_{i,j} = \lambda d^{(1)}(i, j) + (1 - \lambda) d^{(2)}(i, j) \quad (4-4)$$

其中, d_j 表示第 j 个检测框信息 (u, v, s) , y_i 为预测的目标位置, $\mathbf{S}_i$ 表示卡尔曼滤波预测得到的协方差矩阵; r_j 表示当前帧中目标的外观特征, $\mathcal{R}_i$ 表示所有历史帧中与该目标相关联的外观特征集; λ 为平衡两种度量影响的权重参数。

4.1.2 ByteTrack 算法

ByteTrack 作为一种基于 TBD 范式的跟踪方法, 区别于只关注高置信度检测框的跟踪算法, 通过引入一种全新的数据关联策略——BYTE, 几乎保留了所有检测框以进行身份匹配, 有效降低了目标漏检率并提高了轨迹连贯性。然而, 由于 ByteTrack 只使用检测算法得到的目标框进行跟踪, 而没有采用 ReID 技术计算外观相似度, 因此这一方法的性能很大程度上依赖于目标检测的准确性^[85]。

BYTE 方法的原理可以理解为, 遮挡通常导致检测置信度逐渐降低。因此, 在遮挡之前可见且置信度较高的目标会形成轨迹; 而当目标遭到遮挡, 即使置信度降低, 基于检测框与已有轨迹的空间重合程度, 仍能够准确识别并维护该目标的轨迹, 从而确保轨迹的连续性与准确性。




图 4.1 ByteTrack 算法流程图

Fig 4.1 Flowchart of ByteTrack algorithm

ByteTrack 的算法流程如图 4.1 所示，数据关联过程采取分阶段处理策略：

(1) 检测结果分类：首先，基于置信度将检测结果划分为两类：高置信度检测框和低置信度检测框。如果检测框的置信度高于预设的高置信度阈值(0.5)，则被分入高置信度集合 D_{high} ；若置信度位于高置信度阈值与低置信度阈值(0.15)之间，则分入低置信度集合 D_{low} 。

(2) 初次关联匹配：将高置信度检测框 D_{high} 与已有轨迹进行初次关联匹配。计算 D_{high} 与现有轨迹的代价矩阵，通过匈牙利算法进行匹配。匹配成功的轨迹通过卡尔曼滤波更新，并包含在当前帧轨迹集合内。未匹配成功的轨迹被记录为 T_{remain} ，未匹配的高置信度检测框记录为 D_{remain} 。

(3) 第二次关联匹配：将低置信度检测框 D_{low} 与未匹配轨迹 T_{remain} 轨迹进行第二次关联匹配。再次计算代价矩阵，通过匈牙利算法进行匹配。未成功匹配的轨迹被加入到丢失轨迹集合 T_{lost} 中，未匹配的低置信度检测框视为背景并删除。匹配成功的轨迹通过卡尔曼滤波更新后，纳入当前帧轨迹集合。

(4) 轨迹创建、删除和合并：对于 D_{remain} 中的检测框，如果其置信度超过跟踪得分阈值(0.5)，则创建新轨迹并合并至当前帧轨迹集合；否则，不做处理。对于保留在 T_{lost} 中超过 30 帧的轨迹，视为丢失并删除。此过程整合并输出当前帧的所有轨迹，为下一帧的处理提供已有轨迹集合，并使用卡尔曼滤波预测新轨迹位置。

4.2 基于混合特征自适应匹配的细胞跟踪算法

本研究提出了一种基于混合特征自适应匹配的 HFM-Tracker 细胞跟踪算法，算法首先采用结合细胞形态特征和混合运动特征的 ACM 模块来关联细胞的运动轨迹。接着，通过卡尔曼滤波器，结合细胞过往状态和当前观测到的运动信息，预测细胞未来的位置，从而实现精准的轨迹跟踪。具体算法流程如图 4.2 所示。

在数据关联阶段，HFM-Tracker 从两个维度构建代价矩阵：混合运动特征与形态特征。本文从三个方面进行混合运动特征提取：广义交并比(Generalized Intersection over Union, GIoU)^[86]、欧式距离和目标面积比，同时采用跟踪目标面积比和欧式距离的历史变化均值来约束这些特征。在形态特征方面，采用基于尺度不变特性的 Hu 不变矩方法提取细胞轮廓，并通过自适应计算策略调整混合运动特征和形态特征权重。

随后，算法采用卡尔曼滤波器，结合被跟踪细胞的历史状态和观察到的运动信息，来预测其未来状态。无法与当前检测相关联的轨迹被归类为不匹配轨迹，相应地，未能与现有轨迹匹配的检测则被标记为不匹配检测。成功匹配的轨迹将得到更新，并继续参与跟踪。算法将删除在 30 帧内未更新的不匹配轨迹，以减少错误跟踪的积累。对于那些置信度较低的检测框，算法会评估判断它们是否代表真实目标，并为确认为实际物体的不匹配检测创建新轨迹。通过不断更新卡尔曼滤波器，算法不仅优化了细胞跟踪的精确度，还确保了预测结果与实际观测之间的高度一致性。




图 4.2 细胞跟踪算法框架图

Fig 4.2 Framework diagram of the cell tracking algorithm

4.2.1 混合运动特征

本文从三个方面进行细胞运动特征提取：GIoU、欧式距离和细胞面积比，对于细胞检测轮廓 i 和细胞轨迹 j ，根据细胞运动特征得到的代价矩阵用 $cost^{motion}$ 表示，如式(4-5)所示：

$$cost^{motion} = aL_{ij}^{GIoU} + bL_{ij}^{dist} + cL_{ij}^{area} \quad (4-5)$$

其中， a 、 b 和 c 分别表示 GIoU、欧式距离和面积比的平衡系数， L_{ij}^{GIoU} 、 L_{ij}^{dist} 和 L_{ij}^{area} 分别表示细胞检测框 i 和细胞轨迹 j 在 GIoU、欧式距离和面积比上的相似性。

(1) GIoU 特征。IoU 是当前帧预测轨迹位置与检测框之间重叠度的一种度量方法，用于衡量跟踪轨迹附近对象之间的相似性。基于卡尔曼滤波的预测框与检测框之间重叠程度越高，该检测框就越有可能代表当前时刻轨迹移动的位置。对象之间基于 IoU 的相似性 L_{ij}^{IoU} 计算如式(4-6)、式(4-7)所示：

$$L_{ij}^{IoU} = 1 - IoU_{ij} \quad (4-6)$$

$$IoU_{ij} = \frac{Area_i \cap Area_j}{Area_i \cup Area_j} \quad (4-7)$$

GIoU 是基于 IoU 的一种改进方法，它考虑了当两个区域不相交时 IoU 指标的不足。GIoU 在 IoU 的基础上增加了最小封闭矩形的概念，即使两个框没有重叠部分，GIoU 仍然可以反映它们之间的距离和空间关系。因此，本文使用 GIoU 作为相似性度量能够提供更准确的目标位置匹配，并优化跟踪性能。对象之间基于 GIoU 的相似性 L_{ij}^{GIoU} 计算如式(4-8)、式(4-9)所示：

$$L_{ij}^{GIoU} = 1 - GIoU_{ij} \quad (4-8)$$

$$GIoU_{ij} = IoU_{ij} - \frac{C - (A \cup B)}{C} \quad (4-9)$$

其中, $A \cup B$ 表示轮廓 A 和轮廓 B 的并集, C 表示最小封闭区域的面积。

(2) 欧氏距离特征。在使用卡尔曼滤波进行目标运动预测时, 如果目标的预测框与检测框恰好构成包含关系, $GIoU$ 会退化成传统的 IoU , 如图 4.3(a) 所示, 这种情况下, $GIoU$ 无法有效区分其相对位置关系, 不能充分识别这两个框的空间位置关系。此外, 当两个框在水平方向上距离相等时, $GIoU$ 对垂直方向距离的变化不够敏感, 如图 4.3(b) 所示, 反之亦然, 这种情况会导致模型收敛速度变慢。因此, 基于 $GIoU$ 的运动特征相似性度量在某些情况下不够有效, 无法准确反映检测框与轨迹的关联。




图 4.3 目标框位置关系示意图: (a) 包含关系, (b) 无相交关系

Fig 4.3 Schematic representation of the positional relationship of the target frame: (a) inclusion relationship, (b) no intersection relationship

鉴于 $GIoU$ 在某些情况下的局限性, 特别是在跟踪轨迹附近不存在交集框的场景中, 引入欧式距离作为一种补充特征就显得非常关键。与 $GIoU$ 不同, 欧式距离能有效衡量当目标检测框与预测轨迹间没有直接重叠时的匹配程度。

在代价矩阵的计算中, 本文加入了欧式距离作为补充特征, 并设置了两项约束: 首先对于那些与跟踪轨迹相距甚远的目标, 将其匹配度设定为较低的相似度, 从而排除这些非潜在目标; 然后利用轨迹的平均移动距离预测目标在当前帧中可能出现的位置, 作为变化的欧式距离纳入代价矩阵, 并与时间累积数据相结合, 用以加强对跟踪过程的约束。

对于一组从 t_1 到 t_2 帧的跟踪轨迹 i 和检测框 j , 基于欧式距离的相似性 L_{ij}^{dist} 计算如式 (4-10)、式 (4-11) 所示:

$$L_{ij}^{\text{dist}} = \begin{cases} 1 - \frac{\text{dist}_{ij}}{M}, & \text{dist}_{ij} \leq \mu \text{Avg}_i^{\text{dist}} \\ \text{INF}, & \text{dist}_{ij} > \mu \text{Avg}_i^{\text{dist}} \end{cases} \quad (4-10)$$

$$\text{Avg}_i^{\text{dist}} = \frac{\sum_{t=t_1}^{t_2} \text{dist}_k}{t_2 - t_1} \quad (4-11)$$

其中, $dist_{ij}$ 表示从跟踪轨迹 i 的中心到对象检测框 j 的中心的欧式距离, M 表示当前图像的对角线长度, Avg_i^{dist} 表示跟踪轨迹 i 从 t_1 到 t_2 帧移动距离的平均值, μ 表示移动范围缩放系数, INF 为距离超出 Avg_i^{dist} 的最大值, $dist_k$ 表示跟踪轨迹 i 在 k 时刻的欧式距离。

(3) 面积比特征。基于 GIoU 和欧式距离的运动特征能在一定程度上反映检测框与跟踪轨迹之间的相似性, 但这种度量方式主要关注图像的位置信息。然而, 细胞的形态是动态变化的, 可能会发生伸缩等运动, 导致连续帧中检测框的尺寸发生变化。

针对这一问题, 本研究引入了跟踪轨迹与检测框之间的面积比特征来评估运动相似度, 并且与基于欧式距离的运动特征提取方法相似, 还加上了时间信息的约束。首先根据式(4-12)和式(4-13), 动态更新从 t_1 到 t_2 帧之间现有轨迹的平均面积比 Avg_i^{ratio} 。然后根据式(4-14)计算当前检测框和跟踪框的面积比 $ratio_{ij}$, 最后通过比较 $ratio_{ij}$ 与 Avg_i^{ratio} , 即可得到面积相似度 L_{ij}^{area} , 如式(4-15)所示, 其中, v 是跟踪轨迹目标框的面积比变化范围缩放系数。

$$ratio_t = \begin{cases} \frac{area_{t-1}}{area_t}, & t > t_1, area_{t-1} < area_t \\ \frac{area_t}{area_{t-1}}, & t > t_1, area_{t-1} > area_t \end{cases} \quad (4-12)$$

$$Avg_i^{ratio} = \frac{\sum_{t=t_1}^{t_2} ratio_t}{t_2 - t_1} \quad (4-13)$$

$$ratio_{ij} = \begin{cases} \frac{area_i}{area_j}, & area_i < area_j \\ \frac{area_j}{area_i}, & area_i > area_j \end{cases} \quad (4-14)$$

$$L_{ij}^{area} = \begin{cases} 1 - ratio_{ij}, & \frac{1}{v} Avg_i^{ratio} \leq ratio_{ij} \leq v Avg_i^{ratio} \\ INF, & \text{other} \end{cases} \quad (4-15)$$

将目标面积比特征纳入代价矩阵, 不仅考虑到了目标框在图像中的空间位置, 还兼顾了尺寸变化的重要信息, 使得运动特征相似度评估不再单一依赖于空间位置, 而是形成了一个更为综合的评价体系。此外, 引入时间信息的约束使得跟踪算法能够更全面地考虑目标运动的连续性与稳定性, 从而为跟踪提供了更加丰富和精准的上下文依据。

4.2.2 细胞形态特征

依赖于运动特征的数据关联方法在从形态学角度评估跟踪轨迹与当前检测框之间的相似性时存在局限, 特别是在目标密集和频繁遮挡的场景中, 运动特征往往难以有效区分跟踪轨迹附近不同物体检测框。考虑到本文提出的基于轮廓注意力的 CAPCD 算法能够精确提取细胞轮廓, 有效地保留了细胞的形态学特征, 因此, 本研究采用了改进的基于尺度不变特性的 Hu 不变矩作为特征描述子, 以提取目标的形态特征。

矩是描述图像特征的算子, 广泛应用于图像分析和特征提取。常见的矩算子类型包括几何矩、复数矩、旋转矩和正交矩, 其中几何矩是最早提出且研究最深入的。几何矩揭示了图像区域的几何属性, 因其具备对平移、旋转和缩放操作的不变性, 故又称为不

变矩。对于一幅图像，几何矩定义如式(4-16)所示：

$$m_{pq} = \sum_x \sum_y x^p y^q f(x, y) \quad (4-16)$$

其中， $f(x, y)$ 是图像在 (x, y) 的像素值， p 和 q 是非负整数，分别代表矩的水平和垂直阶数。

零阶矩 m_{00} 代表了图像的总灰度和，实际上等于图像的面积，如式(4-17)所示：

$$m_{00} = \sum_x \sum_y f(x, y) \quad (4-17)$$

一阶矩反映了图像的质心(即图像的平均灰度坐标)。 m_{10} 和 m_{01} 分别表示图像在 x 和 y 方向上的一阶矩，用于计算图像的质心位置，如式(4-18)、式(4-19)所示：

$$m_{10} = \sum_x \sum_y x f(x, y) \quad (4-18)$$

$$m_{01} = \sum_x \sum_y y f(x, y) \quad (4-19)$$

二阶矩也称为惯性矩。 m_{20} 和 m_{02} 分别为围绕质心的水平方向和垂直方向的惯性矩，其表达式如式(4-20)、式(4-21)所示：

$$m_{20} = \sum_x \sum_y x^2 f(x, y) \quad (4-20)$$

$$m_{02} = \sum_x \sum_y y^2 f(x, y) \quad (4-21)$$

如果 $m_{20} > m_{02}$ ，则说明图像在水平方向上的分布范围大于垂直方向，可以视为图像在水平方向上的伸展更为明显。反之则说明图像在垂直方向上的拉伸更为显著。

三阶矩是图像分析中用于评估形状分布偏斜程度的重要指标，反映了图像形状的非对称性。 m_{30} 和 m_{03} 分别衡量图像沿水平和垂直方向的倾斜，如式(4-22)、式(4-23)所示：

$$m_{30} = \sum_x \sum_y x^3 f(x, y) \quad (4-22)$$

$$m_{03} = \sum_x \sum_y y^3 f(x, y) \quad (4-23)$$

中心矩是几何矩的变体，是相对于图像质心计算的，描述了图像形状关于其重心的分布，与位置无关，如式(4-24)所示：而为了使矩对尺寸变化具有不变性，引入归一化中心矩 η_{pq} ，使得矩描述符不受图像尺寸的影响，仅反映图像的形状特性，其计算公式如式(4-25)、式(4-26)所示：

$$\mu_{pq} = \sum_x \sum_y (x - \bar{x})^p (y - \bar{y})^q f(x, y) \quad (4-24)$$

$$\gamma = \frac{p+q}{2} + 1, \quad (p+q = 2, 3, 4 \dots) \quad (4-25)$$

$$\eta_{pq} = \frac{\mu_{pq}}{\mu_{00}^\gamma} \quad (4-26)$$

其中， $\bar{x} = m_{10}/m_{00}$ ， $\bar{y} = m_{01}/m_{00}$ 。 μ_{pq} 为原始的中心矩， μ_{00}^γ 是图像区域的零阶中心矩，

代表整个图像的面积, 指数 γ 确保了不同尺寸的图像在形状分析时能够被公平比较。

基于上述归一化中心矩 η_{pq} , Hu 不变矩的不变矩组 $M_1 - M_7$ 的计算如式(4-27)所示:

$$\begin{cases} M_1 = \eta_{20} + \eta_{02} \\ M_2 = (\eta_{20} - \eta_{02})^2 + 4\eta_{11}^2 \\ M_3 = (\eta_{30} - 3\eta_{12})^2 + (3\eta_{21} - \eta_{03})^2 \\ M_4 = (\eta_{30} + \eta_{12})^2 + (\eta_{21} + \eta_{03})^2 \\ M_5 = (\eta_{30} - 3\eta_{12})(\eta_{30} + \eta_{12})[(\eta_{30} + \eta_{12})^2 - 3(\eta_{21} + \eta_{03})^2] \\ \quad + (3\eta_{21} - \eta_{03})(\eta_{21} + \eta_{03})[3(\eta_{30} + \eta_{12})^2 - (\eta_{21} + \eta_{03})^2] \\ M_6 = (\eta_{20} - \eta_{02})[(\eta_{30} + \eta_{12})^2 - (\eta_{21} + \eta_{03})^2] + 4\eta_{11}(\eta_{30} + \eta_{12})(\eta_{21} + \eta_{03}) \\ M_7 = (3\eta_{21} - \eta_{03})(\eta_{30} + \eta_{12})[(\eta_{30} + \eta_{12})^2 - 3(\eta_{21} + \eta_{03})^2] \\ \quad + (\eta_{30} - 3\eta_{12})(\eta_{21} + \eta_{03})[3(\eta_{30} + \eta_{12})^2 - (\eta_{21} + \eta_{03})^2] \end{cases} \quad (4-27)$$

这七个不变矩组是通过组合低阶矩计算得到, 能够提供图像的基本形状特征, 而且对图像平移、旋转和缩放保持不变性。这种不变性确保无论图像如何移动或变形, 这些不变矩的计算结果保持一致, 从而为图像之间的形状相似性提供了一种比较基准。

Hu 不变矩是一种与图像灰度值相关的区域矩, 其计算涉及整个图像区域, 导致计算成本相对较高。此外, 在处理形态接近、内部特征分布均匀的细胞时, 边缘像素的变化会影响面积因子零阶矩 m_{00} 的计算结果, 不符合边界矩的不变性要求。

针对这一问题, 本研究提出了一种基于尺度不变特性的 Hu 不变矩, 通过采用矩之间的比率来消除比例因子 m_{00} 的影响, 并加入离心率特征 ϕ_8 , 从而确保得到的不变矩仅与细胞轮廓的几何形状相关, 而与面积或其它结构的比例尺度无关。改进后的 Hu 不变矩组公式如式(4-28)所示:

$$\begin{cases} \phi_1 = \frac{\sqrt{M_2}}{M_1} = \frac{\sqrt{(\eta_{20} - \eta_{02})^2 + 4\eta_{11}^2}}{\eta_{20} + \eta_{02}} \\ \phi_2 = \frac{M_1 + \sqrt{M_2}}{M_1 - \sqrt{M_2}} \\ \phi_3 = \frac{\sqrt{M_3}}{\sqrt{M_4}} \\ \phi_4 = \frac{\sqrt{M_3}}{\sqrt{M_5}} \\ \phi_5 = \frac{\sqrt{M_4}}{\sqrt{M_5}} \\ \phi_6 = \frac{M_6}{M_1 \cdot M_3} \\ \phi_7 = \frac{M_6}{\sqrt{M_5}} \\ \phi_8 = \frac{(m_{20} - m_{02})^2 + 4m_{11}}{m_{20} + m_{02}} \end{cases} \quad (4-28)$$

其中, ϕ_1 代表轮廓的曲率半径。 ϕ_8 表示轮廓最大轴与最短轴之比。

为了精确衡量细胞形态间的相似度并有效提取轮廓特征,本研究首先对轮廓 A 和 B 的 Hu 不变矩组进行归一化处理,再计算其逆差异度,从而得到基于形态特征的代价矩阵 $cost^{mor}$ 。通过比较两个轮廓在每个 Hu 不变矩上的逆差异度,来量化它们形态的差异。差异值越小,表明两个细胞形态越相似。具体计算如式(4-29)、式(4-30)所示:

$$\begin{cases} \psi_i^A = \text{sign}(\Phi_i^A) \cdot \log_2 |\Phi_i^A| \\ \psi_i^B = \text{sign}(\Phi_i^B) \cdot \log_2 |\Phi_i^B| \end{cases}, i = 1, 2, \dots, 8 \quad (4-29)$$

$$cost^{mor} = \sum_{i=1 \dots 7} \left| \frac{1}{\psi_i^A} - \frac{1}{\psi_i^B} \right| \quad (4-30)$$

其中, ψ_i^A 和 ψ_i^B 分别表示轮廓 A 和 B 的第 i 个 Hu 不变矩。

4.2.3 自适应特征匹配策略

在传统的目标跟踪方法中,基于加权的特征匹配(Weight-based Feature Matching, WFM)方法通过对不同特征(如运动和外观)进行人为权重分配,计算多种特征的代价矩阵。具体来说,对于跟踪轨迹 i 的中心和对象检测框 j ,根据混合运动特征计算得到的 $cost_{ij}^{motion}$ 和形态特征计算得到的 $cost_{ij}^{mor}$,通过权重 l 进行加权,得到加权后的代价矩阵 $cost_{ij}^{(1)}$,如式(4-31)所示:

$$cost_{ij}^{(1)} = l cost_{ij}^{motion} + (1 - l) cost_{ij}^{mor} \quad (4-31)$$

虽然这种方法结合了运动和形态特征,但手动设置权重高度依赖先验知识,导致算法在不同场景下的适应性和泛化性不足,尤其是在面对目标密集、频繁遮挡等复杂情况时,形态特征往往难以区分。为了克服手动加权方法的缺点,本文采用了一种自适应特征匹配策略(Adaptive Feature Matching, AFM),充分利用形态和运动特征,自适应计算代价矩阵。

具体来说,本文采取两阶段匹配策略:在第一阶段,使用混合运动代价矩阵 $cost^{motion}$ 和受 GIoU 约束的形态特征代价矩阵 $cost^{GIoU, mor}$ 分别进行匈牙利匹配,得到两组匹配结果 M_A 和 M_B 。在 $cost^{GIoU, mor}$ 中,GIoU 是一种约束条件,用来提出看似相似但距离过远的目标框。随后,提取 M_A 和 M_B 中共同的匹配对,合并为匹配集 M_1 。 $cost^{motion}$ 和 $cost^{GIoU, mor}$ 的计算公式分别如式(4-32)、式(4-33)所示。在第二阶段,对于未匹配的检测框和未包含在匹配集 M_1 中的跟踪轨迹,代价矩阵 $cost^{ada}$ 会以自适应的选择重新计算,然后根据 $cost^{ada}$ 应用匈牙利算法,得到匹配集 M_2 。最后将匹配集 M_1 和 M_2 结合起来,生成最终的匹配结果 M 。 $cost^{ada}$ 的计算公式如式(4-34)所示:

$$cost^{motion} = aL_{ij}^{GIoU} + bL_{ij}^{dist} + cL_{ij}^{area} \quad (4-32)$$

$$cost^{GIoU, mor} = \omega cost^{GIoU} + (1 - \omega) cost^{mor} \quad (4-33)$$

$$cost^{ada} = \min(cost^{motion}, cost^{GIoU, mor}) \quad (4-34)$$

4.3 实验结果分析

4.3.1 评价指标

理想的多目标跟踪结果应该符合以下条件:一是能够及时识别并跟踪出现的目标;

二是确保跟踪目标位置和真实位置的一致性,三是在连续帧中保持目标 ID 的一致性,避免目标 ID 的错误切换。

对于多目标跟踪来说,首先需要明确三种错误跟踪状态:漏检(False Negative, FN)、误检(False Positive, FP)、错配(Mismatch)^[87]。如图 4.4 所示。其中 o 为观测目标,即目标检测网络的检测结果; h 是跟踪量,即目标跟踪网络预测的目标位置,在 h 和 o 之间建议最大可能性连接,超过一定阈值距离就判定无法连接。

漏检的目标是没有与任何跟踪量(预测的目标位置)相匹配的检测结果。误检的目标是检测到的,但实际上并不存在的目标,即没有对应真实目标的跟踪量。而错配发生在目标 ID 在连续帧中错误地切换时,尤其是当多个目标交叉或相遇时,跟踪算法可能将同一目标的 ID 错误地分配给其他目标,导致目标 ID 的不一致。如图 4.4(a)所示, o_1 和 o_2 代表成功匹配并跟踪的目标, o_8 是漏检状态的目标,与之没有匹配的跟踪量, h_5 是不存在但被检测为存在的误检目标。图 4.4(b)展示了三个不同轨迹中目标交叉相遇导致的错配问题,这种情况会导致目标 ID 错误切换,增加了 ID 切换的次数。




图 4.4 多种目标跟踪状态示意图

Fig 4.4 Schematic diagram of multiple object tracking states

为了评估本章提出的基于混合特征自适应匹配的细胞跟踪算法的有效性,本研究主要采用多目标跟踪准确度 MOTA(Multiple Object Tracking Accuracy, MOTA)^[88]、ID 识别 F 值 IDF1(ID F1 Score, IDF1)^[88]和高阶跟踪精度 HOTA(Higher Order Tracking Accuracy, HOTA)^[89]作为实验评估的主要标准。

MOTA 通过综合考虑目标误检数、漏检数和 ID 切换数量来计算跟踪精度,计算公式如式(4-35)所示:

$$MOTA = 1 - \frac{\sum_t (FP_t + FN_t + IDS_t)}{\sum_t GT_t} \quad (4-35)$$

其中, IDS_t 表示发生 ID 切换的目标数量; GT_t 表示 t 时间内的真实目标数量。

IDF1 是一种基于目标 ID 识别的 F1 分数,通过对正确匹配的目标 ID 数量进行评估,并将这个数量与实际检测到的目标数量以及被跟踪到的目标数量的总和进行比较来计算。IDF1 是 ID 精确率(ID Precision, IDP)和 ID 召回率(ID Recall, IDR)的调和平均,其

计算方法如式(4-36)-式(4-38)所示:

$$IDP = \frac{IDTP}{IDTP + IDFP} \quad (4-36)$$

$$IDR = \frac{IDTP}{IDTP + IDFN} \quad (4-37)$$

$$IDF1 = \frac{2}{\frac{1}{IDP} + \frac{1}{IDR}} = \frac{2IDTP}{2IDTP + IDFP + IDFN} \quad (4-38)$$

其中, IDTP 表示正确跟踪的目标 ID 数量; IDFP 表示错误分配的目标 ID 数量; IDFN 表示漏检或未分配的目标 ID 数量。

HOTA 是一种更加全面的评估指标, 综合考虑了定位、检测、关联三种子任务的评价指标, 它将跟踪任务分为这三个子任务, 并采用 IoU 为每个子任务计算得分。对于给定的局部化阈值 α , HOTA 通过平衡检测精度和关联精度来衡量跟踪的整体准确性。HOTA 得分通过在 0 到 1 范围内对 $HOTA_\alpha$ 积分获得, 实际应用中是通过一系列特定 IoU 阈值($\alpha = 0.05, 0.1, \dots, 1$)的 $HOTA_\alpha$ 求和取平均来近似计算。具体计算公式如式(4-39)-式(4-42)所示:

$$DetA_\alpha = \frac{|TP|}{|TP| + |FN| + |FP|} \quad (4-39)$$

$$AssA_\alpha = \frac{1}{|TP|} \sum_{c \in TP} \frac{|TP(c)|}{|TP(c)| + |FN(c)| + |FP(c)|} \quad (4-40)$$

$$HOTA_\alpha = \sqrt{DetA_\alpha \cdot AssA_\alpha} \quad (4-41)$$

$$HOTA = \int_0^1 HOTA_\alpha d\alpha \approx \frac{1}{19} \sum_{\alpha \in 0.05, 0.1, \dots, 1} HOTA_\alpha \quad (4-42)$$

其中, $DetA_\alpha$ 和 $AssA_\alpha$ 分别表示目标的检测准确度和关联准确度。

4.3.2 结果分析

为了验证本章提出的基于混合特征自适应匹配的细胞跟踪算法的有效性, 本文设计了以下实验: 在含不同浓度过氧化氢的 MCF-7 肿瘤细胞数据集上进行对比实验; 改进的和原始 Hu 不变矩方法的对比实验; AFM 策略和 WFM 策略的对比实验; 网络各个模块的消融实验; 在 MCF-7 和 Fluo-C2DL-Huh7 细胞数据集上与当前最先进的多目标跟踪算法的对比实验。

本研究在六组不同过氧化氢浓度的 MCF-7 肿瘤细胞数据集上进行细胞跟踪实验, 并从中选取了第 1 帧、第 50 帧和第 100 帧的图像进行可视化分析, 实验结果如图 4.5 所示。可以看到在第 50 帧时跟踪效果较好, 大部分细胞都能成功跟踪。然而, 在第 100 帧时, 由于细胞聚集区域较多, 细胞粘连现象较多, 未跟踪到的细胞数量增多。考虑是由于此时细胞聚集区域的密度较大, 使得细胞检测框难以达到设定的匹配阈值。这表明本算法在处理密集区域目标的跟踪能力仍存在局限。




图 4.5 不同浓度过氧化氢 MCF-7 肿瘤细胞数据集跟踪结果对比

Fig 4.5 Comparison of tracking results for different concentrations of hydrogen peroxide MCF-7 tumour cells dataset

本研究提出了一种基于尺度不变特性的 Hu 不变矩方法，该方法通过采用矩之间的

比例关系，确保不变矩仅与细胞轮廓的几何形状相关。为了评估这种改进方法的有效性，本文在 MCF-7 肿瘤细胞数据集上，进行了本文提出方法与原始 Hu 不变矩方法的对比实验。在实验中，除了 Hu 不变矩方法外，其他细胞特征提取方法和匹配策略均保持不变。实验结果如表 4.1 所示，其中“↑”表示指标越高越好，“↓”表示指标越低越好。可以看到本文提出方法对模型的性能有较大提升，改进后的 Hu 不变矩方法通过仅依赖细胞轮廓的几何形状，能够更有效地捕捉到图像的边界和结构特征信息，提供对细胞形态特征更为精确的表征，进而提高了细胞跟踪的准确性。

表 4.1 改进 Hu 不变矩的对比实验

Table 4.1 Comparative experiments for improving Hu invariant moments						
Method	HOTA(%)↑	MOTA(%)↑	IDF1(%)↑	FP↓	FN↓	IDS↓
Hu 不变矩	60.1	74.8	65.3	293	2193	425
改进 Hu 不变矩	60.8	75.4	65.7	284	2155	413

为了验证 AFM 匹配策略的有效性，本研究在 MCF-7 肿瘤细胞数据集上进行实验，比较了 AFM 匹配策略和不同权重配置下的 WFM 匹配策略。在进行 WFM 匹配策略的实验时，检测器的阈值和匹配阈值等主要参数在不同权重设置下均保持不变，以控制变量。实验结果如表 4.2 所示，可以看到在 HOTA、MOTA 和 IDF1 这三项关键指标，AFM 策略相较于各种权重配置的 WFM 策略均显示出了更高的性能。AFM 策略通过在初步匹配阶段利用运动和形态特征进行独立匹配，再通过自适应策略对未匹配项进行处理，有效地结合了运动特征和形态特征，提升了模型整体的跟踪性能。值得注意的是，随着形态特征权重的增加，MOTA 和 IDF1 指标总体上呈现下降趋势，说明在目标匹配过程中，相比于运动特征，形态特征应被视为辅助性参考。

表 4.2 AFM 和 WFM 匹配策略实验对比

Table 4.2 Experimental comparison of AFM and WFM matching strategies					
Method	Motion	Morphology	HOTA(%)↑	MOTA(%)↑	IDF1(%)↑
WFM	0.05	0.95	51.2	71.3	49.6
	0.15	0.85	53.1	74.6	58.4
	0.25	0.75	55.2	74.1	61.1
	0.35	0.65	54.5	74.8	62.3
	0.45	0.55	55.1	75.1	62.1
	0.55	0.45	56.5	74.8	63.0
	0.65	0.35	57.2	74.9	63.9
	0.75	0.25	58.4	74.4	64.8
	0.85	0.15	59.1	75.0	64.5
	0.95	0.05	59.3	74.6	64.6
AFM			60.8	75.4	65.7

为了深入探究本文提出的各模块对算法性能的具体贡献，本文以第三章提出的基于轮廓注意力的 CAPCD 网络和 ByteTrack 跟踪算法作为 Baseline，在含有 250 μM 过氧化氢的 MCF-7 肿瘤细胞数据集上进行消融实验，以评估 CMF 形态特征、MMF 运动特征和 AFM 匹配策略的有效性，实验结果如表 4.3 所示。

从表 4.3 的实验 2 和实验 3 结果可以看出, 加入 MMF 运动特征后, 模型的性能得到了明显提升, HOTA 指标提升了 1.2%。相比之下, 模型加入 CMF 形态特征后在 HOTA 指标上的提升仅为 0.8%。表明运动特征对于提高跟踪精度更为重要, 这也与不同权重配置的 WFM 策略实验结果相一致。

与仅使用单一特征的实验相比, 实验 4 在所有关键指标上均表现最优, 这表明只有有效结合细胞运动特征和形态特征, 才能最大化地提高模型的性能。此外, 实验 5 的结果在 HOTA 指标上提升了 0.9%, 验证了本文提出的 AFM 匹配策略在多目标跟踪中的有效性。AFM 策略通过灵活地结合运动和形态特征, 为模型提供了更准确的匹配能力, 从而有效提高了跟踪性能。

表 4.3 模块消融实验对比

Table 4.3 Comparison of module ablation experiments

Study	Baseline	CMF	MMF	AFM	HOTA(%)↑	MOTA(%)↑	IDF1(%)↑
1	√				58.6	70.8	59.4
2	√	√			59.4	72.1	62.3
3	√		√		59.8	73.0	62.6
4	√	√	√		59.9	73.2	63.0
5	√	√	√	√	60.8	75.4	65.7

为了评估所提出模型的性能, 本文在含 250 μM 过氧化氢浓度的 MCF-7 肿瘤细胞数据集上对比了现阶段最先进的目标跟踪网络, 包括 JDT 范式的 JDE^[90]、FairMOT^[80], 以及 DBT 范式的 DeepSORT^[18]、ByteTrack^[21]和 BotSORT^[91], 其中所有 DBT 范式的算法都采用了第三章提出的基于轮廓注意力的 CAPCD 网络作为其目标检测网络, 实验结果如表 4.4 所示。

结果显示, DBT 范式的算法在减少目标 ID 切换方面表现优于 JDT 范式的算法。这表明 DBT 范式在保持目标 ID 持续性方面更为有效。DeepSORT 主要依赖外观信息来改进跟踪性能, 但无法有效分辨识别高度相似的细胞, 性能表现最差。FairMOT 算法采用单一网络架构, 通过添加并行分支来估计像素级 Re-ID 特征, 同时兼顾目标检测和身份跟踪, 实现了较好的性能表现, BotSORT 引入了更深层次的特征学习和匹配机制, 性能仅次于本文所提出的算法。本章所用算法通过利用细胞多维度特征和自适应特征匹配策略, 确保模型能够准确学习到细胞轮廓的关键特征, 为连续帧之间的细胞匹配提供了坚实的基础, 从而实现了较好的跟踪效果。

表 4.4 不同模型实验结果对比

Table 4.4 Comparison of experimental results for different models

Models	HOTA(%)↑	MOTA(%)↑	IDF1(%)↑	FP↓	FN↓	IDS↓
JDE ^[90]	54.3	61.9	50.7	434	2847	685
FairMOT ^[80]	57.7	69.6	61.5	349	2648	596
DeepSORT ^[18]	50.5	59.7	48.9	502	3086	721
ByteTrack ^[21]	58.6	70.8	59.4	328	2352	459
BotSORT ^[91]	59.2	73.5	62.5	315	2232	457
Proposed Model	60.8	75.4	65.7	284	2155	413

在表 4.5 中，对 DIC-C2DH-HeLa 数据集的不同跟踪模型的性能结果进行了比较，可以观察到本文算法在 HOTA、MOTA 和 IDF1 指标上均展现了优越性，分别达到了 58.1%，73.6%和 63.3%。这些结果不仅表明了所提出算法在细胞跟踪任务上的高效性，也体现了在不同数据集上的泛化能力。

表 4.5 基于 DIC-C2DH-HeLa 数据集的不同跟踪模型结果对比

Table 4.5 Comparison of results of different tracking models based on the DIC-C2DH-HeLa dataset

Models	HOTA(%)↑	MOTA(%)↑	IDF1(%)↑	FP↓	FN↓	IDS↓
JDE	54.2	59.8	49.9	144	949	228
FairMOT	56.6	68.9	60.2	116	882	198
DeepSORT	49.8	58.3	49.6	167	984	240
ByteTrack	56.9	67.1	58.2	109	784	153
BotSORT	57.6	72.0	61.1	105	744	152
Proposed Model	58.1	73.6	63.3	94	718	137

4.3 本章小结

本章主要介绍了一种基于混合特征自适应匹配的细胞跟踪算法，在构建数据关联阶段的代价矩阵时，综合考虑了细胞形态特征和混合运动特征，其中混合运动特征包括 GIoU、欧氏距离和面积比；细胞形态特征则采用基于尺度不变的 Hu 不变矩来表征。算法通过自适应策略来进行特征匹配，以充分利用细胞特征。实验结果表明，本文提出的细胞跟踪算法在自建 MCF-7 肿瘤细胞数据集及 DIC-C2DH-HeLa 公共数据集上相比于现有几种常见的跟踪方法均表现更好，表明了本文的有效性。

第5章 细胞定位跟踪算法的应用

细胞行为，包括细胞的形态和迁移，直接反映了细胞内张力的动态变化。了解这种细胞行为对于理解组织形成、免疫反应和伤口愈合等基本生物过程至关重要。细胞行为异常可能会导致正常生物功能的损坏，并进一步与畸形、自身免疫性疾病和癌症转移等疾病相关。例如，肿瘤细胞在转移过程中的定向迁移是导致癌症相关死亡的主要原因之一。在转移病变过程中，肿瘤细胞从原发肿瘤中分离出来，通过血管迁移和运输最终形成继发部位，导致严重的器官衰竭。在这些复杂的细胞过程中，细胞运动和细胞形态变化是至关重要的判断指标。因此，跟踪和观察癌细胞的动态迁移以及细胞形态变化，对于识别和研究异常细胞行为、理解癌症的进展至关重要。本研究通过提出的细胞定位跟踪算法，对处于不同状态的 MCF-7 肿瘤细胞（培养液中加入不同浓度的过氧化氢）数据集进行实验，分析其迁移轨迹和形态特征，深入研究细胞的迁移特性及其与细胞迁移相关的生物学过程。

5.1 细胞形态特征分析

细胞形态特征，包括细胞周长(Perimeter)、面积(Area)、圆度(Roundness)以及长短轴比(Aspect Ratio, AR)，如图 5.1 所示，是细胞生物学研究中的重要参数。




图 5.1 细胞形态特征：(a) 周长，(b) 面积，(c) 长径比，(d) 圆度

Fig 5.1 Morphological characteristics of cells: (a) perimeter, (b) area, (c) aspect ratio, (d) roundness

细胞周长是指细胞边缘轮廓线上所有像素点的总和。细胞面积则是指细胞轮廓内所有像素点的数量。长径比，即长短轴比，是细胞的长轴和短轴的比率。长径比越接近于 1，表明细胞形态越接近圆形；而长径比的增加则表示细胞伸长。长径比的计算公式如式 (5-1)所示：

$$AR = \frac{R1}{R2} \quad (5-1)$$

其中, $R1$ 和 $R2$ 分别为椭圆的主轴和次轴。

细胞圆度用于描述细胞形状接近完美圆形的程度, 圆度值越接近 1, 表明细胞形状越接近于圆形, 计算公式如式(5-2)所示:

$$Roundness = \frac{L^2}{4\pi S} \quad (5-2)$$

其中, L 为细胞周长, S 为细胞面积。

5.2 细胞迁移运动分析

如图 5.2 所示, 通过在二维或三维空间中, 绘制随时间变化的 MCF-7 肿瘤细胞质心的轨迹, 可以定量观察细胞群体的迁移行为。三维细胞轨迹如图 5.2(a)所示, 描述了细胞在空间-时间坐标系下的迁移轨迹, 是由一系列的空间位置 $(x(1), y(1)), \dots, (x(k), y(k))$ 和对应的时间点 $t(1), \dots, t(k)$ 组成的有序序列。二维细胞轨迹如图 5.2(b)所示, 描述了细胞在二维空间内随时间移动的路径, 这些空间位置位于二维实数空间 $\mathbb{R}^2$ 中, 而时间点则形成一个增量序列, 表示在连续的移动过程中细胞位置的离散时间记录。起点归一化的细胞轨迹如图 5.2(c)所示, 通过将每个轨迹的所有位置的坐标相对于起始点的位置进行调整得到的, 即将序列中的每个位置坐标减去第一个位置坐标, 以 $(0,0)$ 作为新的起始点。这种处理方式简化了轨迹的分析, 便于比较不同细胞的移动模式。

通过绘制随时间变化的细胞迁移轨迹, 可以直观地观察到细胞群体的迁移行为。这种方法提供了细胞运动的直观视图, 但它只能提供定性的信息。为了深入理解单个细胞以及细胞群体的动态行为, 还需要通过分析细胞移动速度等其他参数来获得更全面的运动特征描述。




图 5.2 细胞轨迹: (a) 空间-时间三维运动轨迹, (b) 二维运动轨迹, (c) 起点归一化的二维运动轨迹

Fig 5.2 Cell trajectories: (a) space-time 3D motion trajectory, (b) 2D motion trajectory, (c) 2D motion trajectory normalised to the starting point

细胞迁移速度是研究细胞动态行为中最常关注的参数之一。细胞迁移速度的测量可以分为两种主要类型: 瞬时速度和平均速率。瞬时速度指的是细胞在两个连续图像帧之间的移动速度, 通过计算这两帧之间细胞位置变化的距离除以时间间隔得到。这个指标

反映了细胞移动速度的瞬时变化,可以用来观察细胞行为在极短时间内的动态变化。相对而言,平均速率是指在观察期间细胞移动速度的整体表现。为了量化平均速率,本研究采用了平均位移(Mean Displacement, MD)作为衡量标准,单位为微米每小时($\mu\text{m/h}$)。 t 时刻的MD计算公式如式(5-3)所示:

$$MD(t) = \frac{1}{n} \sum_{i=1}^n \frac{\sqrt{(x_i(t) - x_i(t-1))^2 + (y_i(t) - y_i(t-1))^2}}{t_{\text{frame}}} \quad (5-3)$$

其中, $x_i(t)$ 和 $y_i(t)$ 分别是第 i 个细胞在 t 时刻的 x 和 y 坐标位置, n 为细胞总数, t_{frame} 为连续两帧之间的时间间隔,本文所用数据集的 t_{frame} 为10分钟。

5.3 化学物质刺激下的细胞活性分析

本研究通过绘制时间序列迁移轨迹,实现了 MCF-7 肿瘤细胞运动过程的可视化,以便更精准地分析迁移特性。如图 5.3(a)所示,描述了一组 MCF-7 肿瘤细胞在 6 h 内的迁移轨迹,每小时选取一幅图像,显示了细胞在基底上的各种迁移行为,视场中的大多数细胞都被成功检测和跟踪到。由图 5.3(b)中可以看出,用相同的颜色标记每个细胞的轮廓形状及其相应的运动轨迹,并分配唯一的细胞 ID,如"cell-1"、"cell-2"等。图 5.3(c)详细展示了“cell-42”这一细胞在 6 小时内的运动轨迹和形态变化。因此可以看到本文提出的算法能有效识别和跟踪细胞群中的单个细胞,为单细胞分析和群体测量提供详细的形态迁移特征数据。




图 5.3 MCF-7 肿瘤细胞迁移运动: (a) 细胞在 6h 内的延时图, (b) 最后一帧的细胞图像, (c) “cell-42” 的运动轨迹和形态变化

Fig 5.3 Migration movement of MCF-7 tumour cells: (a) time-lapse image of cells during 6h, (b) last frame of cell image, (c) trajectory and morphological changes of “cell-42”

本研究利用不同浓度过氧化氢处理 MCF-7 肿瘤细胞,对细胞特征变化的量化进行分析,并对特征参数进行了平均化处理,实验结果如表 5.1 所示。可以看出,细胞的平均周长和面积呈现先增大后减小的趋势。此外,随着过氧化氢浓度的增加,细胞的长径比、圆度以及平均移动速度均呈下降趋势。这些参数的变化表明,随着过氧化氢浓度的提高,细胞活性逐渐下降,最终可能导致细胞形态收缩及死亡。

表 5.1 不同过氧化氢浓度的 MCF-7 肿瘤细胞特征参数对比

Table 5.1 Comparison of characteristic parameters of MCF-7 tumour cells with different hydrogen peroxide concentrations

过氧化氢浓度	Perimeter(μm)	Area(μm^2)	Aspect Ratio	Roundness	MD($\mu\text{m}/\text{h}$)
0 μM	135.63	899.04	1.965	0.649	5.481
50 μM	152.16	1140.38	1.883	0.647	4.008
100 μM	155.42	1159.19	1.873	0.628	4.119
250 μM	142.23	972.89	1.890	0.647	3.476
500 μM	132.25	905.51	1.805	0.686	2.899
1000 μM	91.95	518.51	1.475	0.8041	0.807

本研究利用提出的细胞定位跟踪算法，对 MCF-7 肿瘤细胞在 24 h 内的迁移轨迹进行了跟踪分析。如图 5.4 所示，详细记录了 24 h 内 MCF-7 肿瘤细胞在不同过氧化氢浓度条件下的迁移行为变化。可以看到在正常环境（0 μM 过氧化氢）中 MCF-7 细胞活性较高，部分细胞迁移距离超过 500 μm 。与低浓度过氧化氢，高浓度的过氧化氢（500 μM 过氧化氢）显著抑制了 MCF-7 细胞的迁移活性。从图 5.4(c)起点归一化的二维迁移轨迹表明，细胞的迁移能力在 500 μM 过氧化氢的存在下降低了近一半。




图 5.4 24 h 内细胞跟踪迁移轨迹：(a) 空间-时间三维运动轨迹，(b) 二维运动轨迹，(c) 起点归一化的二维运动轨迹

Fig 5.4 Cell tracking migration trajectories over 24 h: (a) space-time 3D motion trajectories, (b) 2D motion trajectories, (c) 2D motion trajectories normalised to the starting point

本研究详细分析了 MCF-7 细胞在两种不同条件下 24 h 内的形态特征参数变化，所考察的参数包括细胞周长、面积、圆度、长宽比以及平均速度(MD)，结果如图 5.5 所示。可以看出 MCF-7 细胞在过氧化氢存在下细胞圆度和平均速度较正常组的细胞明显要低，大部分 MCF-7 细胞在经过 24 h 过氧化氢处理后细胞形态已经接近正圆形，丧失了特征形状，迁移速度也降至最低，约为 2.7 $\mu\text{m}/\text{h}$ 。




图 5.5 24 h 内细胞特征统计结果对比: (a) 0 μM , (b) 500 μM

Fig 5.5 Comparison of statistical results of cell characterisation over 24 h: (a) 0 μM , (b) 500 μM

本文选取了连续 1 h 内跟踪的六幅图像进行深入分析, 共计 398 个细胞, 包括正常组(图 5.6(a)和图 5.7(a))和 500 μM 过氧化氢组(图 5.6(b)和图 5.7(b))下的细胞。

从图 5.6 可以看到在 MCF-7 细胞群中, 中型细胞占据了大部分, 它们主要是处于细胞分裂间期的细胞。而大细胞和小细胞, 通常处于有丝分裂期, 其体积快速增长后分裂为两个子细胞。细胞周长与面积呈正相关, 细胞圆度通常与面积成反比, 而细胞的长径比则呈相反趋势。细胞的平均周长、圆度和长径比分别约为 150 μm 、0.6、1.8, 表明多数细胞呈低球形度和较尖的角形态。此外小型细胞的圆度接近 1, 进一步证实了这些细胞主要为新分裂的球形细胞。

如图 5.7 所示, 通过比较有无过氧化氢条件下细胞的 MD 散点图, 观察到过氧化氢的存在显著降低了 MCF-7 细胞的 MD, 细胞的速度分布变得更为集中。该结果也在图 5.4 中通过比较不同条件下的细胞运动轨迹得到了进一步的验证。




图 5.6 细胞形态特征对比: (a) 0 μM , (b) 500 μM

Fig 5.6 Comparison of cell morphology characteristics: (a) 0 μM , (b) 500 μM




图 5.7 细胞运动特征对比: (a) 0 μM , (b) 500 μM

Fig 5.7 Comparison of cell motility characteristics: (a) 0 μM , (b) 500 μM

5.4 本章小结

本章主要利用提出的细胞跟踪算法对过氧化氢引起的 MCF-7 肿瘤细胞的形态和迁移变化进行了实验分析, 分别从细胞的周长、面积、圆度、长径比以及移动速度等方面综合考察了细胞的形态和迁移变化, 探究过氧化氢刺激对肿瘤细胞的影响。结果表明过氧化氢会显著降低细胞活性: 过氧化氢浓度越高, 细胞迁移速度越慢, 活性降低, 且在一定过氧化氢浓度下, 会直接导致细胞死亡。这些实验结果对深入理解氧化应激对肿瘤进展的影响具有重要的应用价值。

第6章 总结与展望

6.1 课题研究总结

细胞的行为，如形态变化和运动迁移，直接反映了其内部张力的动态变化。深入研究这些行为对理解组织发育、免疫反应以及伤口愈合等基本生物学过程具有重要意义。异常细胞迁移不仅干扰正常生物功能，而且可能引发多种疾病，如畸形、自身免疫性疾病和癌症的扩散。因此持续跟踪细胞的集体迁移行为，特别是肿瘤细胞迁移及其形态变化的观察，对于识别异常细胞行为和理解肿瘤疾病的进展过程至关重要。

然而，由于显微图像的低信噪比、有限的时空分辨率，以及细胞形态、位置和移动轨迹的不稳定性，传统的多目标跟踪技术难以精确地定位和跟踪细胞。为解决这一难题，本文采用深度学习技术，开发了一种高效而准确的细胞跟踪算法，其中包括基于轮廓注意力的 CAPCD 网络和基于混合特征自适应匹配的细胞跟踪算法，对细胞位置分布和轮廓进行精确的识别与定位，为深入研究肿瘤细胞氧化应激的反应机制奠定了更为稳固的基础。

本文将多细胞跟踪这一研究课题划分为两个关键阶段：每一帧细胞定位检测和连续帧间细胞识别跟踪。这两个阶段共同组成了一个完整的研究过程，旨在精确地定位和跟踪细胞。

(1) 在细胞定位检测方面，本文提出了基于轮廓注意力的 CAPCD 网络，主要包括两个网络模块：ICBM 模型和 COPN 网络。ICBM 模型通过基于目标中心点距离的编码生成热力图，更好地表征物体中心，从而实现可靠的初步检测并定位细胞目标框；而 COPN 网络则利用轮廓注意力图进行细胞轮廓的精确回归。在分割模型训练过程中，为了使模型更加关注细胞相邻轮廓点，提出了一种轮廓点监督的偏移预测损失函数来训练模型。本文在 MCF-7 肿瘤细胞数据集上的 AP 和 AP₅₀ 分别达到了 48.2% 和 87.3%，能精准检测分割大部分细胞轮廓。

(2) 在细胞识别跟踪方面，本文提出了基于混合特征自适应匹配的 HFM-Tracker 细胞跟踪算法，在数据关联阶段通过结合细胞形态特征和运动特征的 ACM 模块来关联细胞的运动轨迹，并利用卡尔曼滤波器综合细胞的过往状态和当前检测到的运动信息，预测细胞未来位置，从而实现精准的细胞跟踪。本文在 MCF-7 肿瘤细胞数据集上的 HOTA 能达到 60.8%，达到了较高的跟踪准确度，减少了细胞漏检情况。

(3) 最后，本文针对含不同浓度过氧化氢培养的 MCF-7 肿瘤细胞进行实验，分别从细胞的周长、面积、圆度、长径比以及移动速度等方面综合考察了细胞的形态和迁移变化，探究了过氧化氢刺激对肿瘤细胞迁移特性和细胞活性的影响，结果表明过氧化氢会显著降低细胞活性。这些实验结果为肿瘤疾病的研究和诊断提供了重要依据。

6.2 后续研究工作展望

本文提出的多细胞跟踪算法虽然取得了不错的结果，但也存在着一定的问题，未来的研究可以围绕以下几个方向进行改进和优化：

(1) 在细胞图像收集过程中，会遇到诸如图像伪影和培养基杂质干扰等问题，影响细胞检测训练效果。后续可以增加图像预处理步骤，通过精确地分离前景细胞与背景，并滤除非细胞物体，从而提高细胞图像的处理质量和跟踪精度。

(2) 在细胞图像的目标密集区域，细胞的遮挡和边界连结现象普遍存在，这使得检测过程中的目标边界难以准确分割，同时在跟踪过程中也导致目标 ID 频繁切换。未来的研究可以考虑引入专门针对下播密集区域的分割损失函数，以增强算法对密集区域细胞的分割能力。

(3) 对于细胞 ID 切换频繁的问题，可以考虑引入基于学习的策略来预测和纠正 ID 切换，通过这种方法，可以提前识别和修正跟踪中可能出现的错误。

参考文献

- [1] Ortega-Carrion A, Feo-Lucas L, Vicente-Manzanares M. Cell Migration [M]//BRADSHAW R A, STAHL P D. Encyclopedia of Cell Biology. Waltham; Academic Press. 2016: 720-30.
- [2] Laviña B, Castro M, Niaudet C, et al. Defective endothelial cell migration in the absence of Cdc42 leads to capillary-venous malformations [J]. Development, 2018, 145(13): dev161182.
- [3] Mosabbir A A, Qudrat A, Truong K. Engineered cell migration to lesions linked to autoimmune disease [J]. Biotechnology and bioengineering, 2018, 115(4): 1028-36.
- [4] Entschladen F, Drell T L, Lang K, et al. Tumour-cell migration, invasion, and metastasis: navigation by neurotransmitters [J]. The lancet oncology, 2004, 5(4): 254-8.
- [5] Fang W, Lv X, Ma Z, et al. A Flexible Terahertz Metamaterial Biosensor for Cancer Cell Growth and Migration Detection [J]. Micromachines, 2022, 13(4): 631.
- [6] Jin X, Demere Z, Nair K, et al. A metastasis map of human cancer cell lines [J]. Nature, 2020, 588(7837): 331-6.
- [7] Novikov N M, Zolotaryova S Y, Gautreau A M, et al. Mutational drivers of cancer cell migration and invasion [J]. British journal of cancer, 2021, 124(1): 102-14.
- [8] Zimmer C, Zhang B, Dufour A, et al. On the digital trail of mobile cells [J]. IEEE Signal Processing Magazine, 2006, 23(3): 54-62.
- [9] Montell D J. Morphogenetic cell movements: diversity from modular mechanical properties [J]. Science, 2008, 322(5907): 1502-5.
- [10] Rai G P, Baird S K. Tissue inhibitor of matrix metalloproteinase-3 has both anti-metastatic and anti-tumorigenic properties [J]. Clinical & experimental metastasis, 2020, 37(1): 69-76.
- [11] Yang X, Li H, Zhou X. Nuclei segmentation using marker-controlled watershed, tracking using mean-shift, and Kalman filter in time-lapse microscopy [J]. IEEE Transactions on Circuits and Systems I: Regular Papers, 2006, 53(11): 2405-14.
- [12] Yang F, Mackey M A, Ianzini F, et al. Cell segmentation, tracking, and mitosis detection using temporal context[C]//International Conference on Medical Image Computing and Computer-Assisted Intervention. Springer, 2005: 302-9.
- [13] Zimmer C, Labruyere E, Meas-Yedid V, et al. Segmentation and tracking of migrating cells in videomicroscopy with parametric active contours: A tool for cell-based drug testing [J]. IEEE transactions on medical imaging, 2002, 21(10): 1212-21.
- [14] Bunyak F, Palaniappan K, Nath S K, et al. Quantitative cell motility for in vitro wound healing using level set-based active contour tracking[C]//3rd IEEE International Symposium on Biomedical Imaging: Nano to Macro, 2006. IEEE, 2006: 1040-3.
- [15] Mendoz E, Lim C T. Collective migration behaviors of human breast cancer cells in 2D [J]. Cellular and Molecular Bioengineering, 2011, 4: 411-26.

- [16] Scherf N, Franke K, Glauche I, et al. On the symmetry of siblings: automated single-cell tracking to quantify the behavior of hematopoietic stem cells in a biomimetic setup [J]. *Experimental hematology*, 2012, 40(2): 119-30. e9.
- [17] Chen X, Zhou X, Wong S T. Automated segmentation, classification, and tracking of cancer cell nuclei in time-lapse microscopy [J]. *IEEE transactions on biomedical engineering*, 2006, 53(4): 762-6.
- [18] Bewley A, Ge Z, Ott L, et al. Simple online and realtime tracking[C]//2016 IEEE international conference on image processing (ICIP).IEEE,2016:3464-8.
- [19] Wojke N, Bewley A, Paulus D. Simple online and realtime tracking with a deep association metric[C]//2017 IEEE international conference on image processing (ICIP).IEEE,2017:3645-9.
- [20] Neubeck A, Van Gool L. Efficient non-maximum suppression[C]//18th international conference on pattern recognition (ICPR'06).IEEE,2006:850-5.
- [21] Zhang Y, Sun P, Jiang Y, et al. Bytetrack: Multi-object tracking by associating every detection box[C]//European conference on computer vision.Springer,2022:1-21.
- [22] Du Y, Zhao Z, Song Y, et al. Strongsort: Make deepsort great again [J]. *IEEE Transactions on Multimedia*, 2023.
- [23] Wang Z, Zheng L, Liu Y, et al. Towards real-time multi-object tracking[C]//European conference on computer vision.Springer,2020:107-22.
- [24] Chen L, Ai H, Zhuang Z, et al. Real-time multiple people tracking with deeply learned candidate selection and person re-identification[C]//2018 IEEE international conference on multimedia and expo (ICME).IEEE,2018:1-6.
- [25] Zhang Y, Wang C, Wang X, et al. A simple baseline for multi-object tracking [J]. *arXiv preprint arXiv:200401888*, 2020, 7(8).
- [26] Zhou X, Koltun V, Krähenbühl P. Tracking objects as points[C]//European conference on computer vision.Springer,2020:474-90.
- [27] Bolya D, Zhou C, Xiao F, et al. Yolact: Real-time instance segmentation[C]//Proceedings of the IEEE/CVF international conference on computer vision.2019:9157-66.
- [28] Amat F, Lemon W, Mossing D P, et al. Fast, accurate reconstruction of cell lineages from large-scale fluorescence microscopy data [J]. *Nature methods*, 2014, 11(9): 951-8.
- [29] Lévy B, Petitjean S, Ray N, et al. Least squares conformal maps for automatic texture atlas generation [M]. *Seminal Graphics Papers: Pushing the Boundaries, Volume 2*. 2023: 193-202.
- [30] Dzyubachyk O, Van Cappellen W A, Essers J, et al. Advanced level-set-based cell tracking in time-lapse fluorescence microscopy [J]. *IEEE transactions on medical imaging*, 2010, 29(3): 852-67.
- [31] Liu M, Liu Y, Qian W, et al. DeepSeed local graph matching for densely packed cells tracking [J]. *IEEE/ACM transactions on computational biology and bioinformatics*, 2019, 18(3): 1060-9.
- [32] Payer C, Štern D, Feiner M, et al. Segmenting and tracking cell instances with cosine embeddings and recurrent hourglass networks [J]. *Medical image analysis*, 2019, 57: 106-

- 19.
- [33]Newell A, Yang K, Deng J. Stacked hourglass networks for human pose estimation[C]//Computer Vision–ECCV 2016: 14th European Conference, Amsterdam, The Netherlands, October 11-14, 2016, Proceedings, Part VIII 14.Springer,2016:483-99.
- [34]Lugagne J-B, Lin H, Dunlop M J. DeLTA: Automated cell segmentation, tracking, and lineage reconstruction using deep learning [J]. PLoS computational biology, 2020, 16(4): e1007673.
- [35]Ronneberger O, Fischer P, Brox T. U-net: Convolutional networks for biomedical image segmentation[C]//Medical image computing and computer-assisted intervention–MICCAI 2015: 18th international conference, Munich, Germany, October 5-9, 2015, proceedings, part III 18.Springer,2015:234-41.
- [36]Chen Y, Song Y, Zhang C, et al. CellTrack R-CNN: A novel end-to-end deep neural network for cell segmentation and tracking in microscopy images[C]//2021 IEEE 18th International Symposium on Biomedical Imaging (ISBI).IEEE,2021:779-82.
- [37]He K, Gkioxari G, Dollár P, et al. Mask r-cnn[C]//Proceedings of the IEEE international conference on computer vision.2017:2961-9.
- [38]Bertinetto L, Valmadre J, Henriques J F, et al. Fully-convolutional siamese networks for object tracking[C]//Computer Vision–ECCV 2016 Workshops: Amsterdam, The Netherlands, October 8-10 and 15-16, 2016, Proceedings, Part II 14.Springer,2016:850-65.
- [39]Yang B, Huang C, Nevatia R. Learning affinities and dependencies for multi-target tracking using a CRF model[C]//CVPR 2011.IEEE,2011:1233-40.
- [40]Pellegrini S, Ess A, Schindler K, et al. You'll never walk alone: Modeling social behavior for multi-target tracking[C]//2009 IEEE 12th international conference on computer vision.IEEE,2009:261-8.
- [41]Meijering E, Dzyubachyk O, Smal I, et al. Tracking in cell and developmental biology[C]//Seminars in cell & developmental biology.Elsevier,2009:894-902.
- [42]Li K, Miller E D, Chen M, et al. Cell population tracking and lineage construction with spatiotemporal context [J]. Medical image analysis, 2008, 12(5): 546-66.
- [43]Duan G, Ai H, Cao S, et al. Group tracking: Exploring mutual relations for multiple object tracking[C]//Computer Vision–ECCV 2012: 12th European Conference on Computer Vision, Florence, Italy, October 7-13, 2012, Proceedings, Part III 12.Springer,2012:129-43.
- [44]严春满, 王铖. 卷积神经网络模型发展及应用 [J]. Journal of Frontiers of Computer Science & Technology, 2021, 15(1).
- [45]Ciaparrone G, Sánchez F L, Tabik S, et al. Deep learning in video multi-object tracking: A survey [J]. Neurocomputing, 2020, 381: 61-88.
- [46]Zou Z, Chen K, Shi Z, et al. Object detection in 20 years: A survey [J]. Proceedings of the IEEE, 2023, 111(3): 257-76.
- [47]Girshick R, Donahue J, Darrell T, et al. Rich feature hierarchies for accurate object detection and semantic segmentation[C]//Proceedings of the IEEE conference on computer vision and pattern recognition.2014:580-7.

- [48]He K, Zhang X, Ren S, et al. Spatial pyramid pooling in deep convolutional networks for visual recognition [J]. IEEE transactions on pattern analysis and machine intelligence, 2015, 37(9): 1904-16.
- [49]王亚东, 田永林, 李国强, et al. 基于卷积神经网络的三维目标检测研究综述 [J]. 模式识别与人工智能, 2021, 34(12): 1103-19.
- [50]Ren S, He K, Girshick R, et al. Faster r-cnn: Towards real-time object detection with region proposal networks [J]. Advances in neural information processing systems, 2015, 28.
- [51]Lin T-Y, Dollár P, Girshick R, et al. Feature pyramid networks for object detection[C]//Proceedings of the IEEE conference on computer vision and pattern recognition.2017:2117-25.
- [52]Liu W, Anguelov D, Erhan D, et al. Ssd: Single shot multibox detector[C]//Computer Vision–ECCV 2016: 14th European Conference, Amsterdam, The Netherlands, October 11–14, 2016, Proceedings, Part I 14.Springer,2016:21-37.
- [53]Bochkovskiy A, Wang C-Y, Liao H-Y M. Yolov4: Optimal speed and accuracy of object detection [J]. arXiv preprint arXiv:200410934, 2020.
- [54]Ge Z, Liu S, Wang F, et al. YOLOX: Exceeding yolo series in 2021 [J]. arXiv preprint arXiv:210708430, 2021.
- [55]Li C, Li L, Jiang H, et al. YOLOv6: A single-stage object detection framework for industrial applications [J]. arXiv preprint arXiv:220902976, 2022.
- [56]Redmon J, Divvala S, Girshick R, et al. You only look once: Unified, real-time object detection[C]//Proceedings of the IEEE conference on computer vision and pattern recognition.2016:779-88.
- [57]Redmon J, Farhadi A. Yolov3: An incremental improvement [J]. arXiv preprint arXiv:180402767, 2018.
- [58]Wang C-Y, Bochkovskiy A, Liao H-Y M. YOLOv7: Trainable bag-of-freebies sets new state-of-the-art for real-time object detectors[C]//Proceedings of the IEEE/CVF conference on computer vision and pattern recognition.2023:7464-75.
- [59]Wang C-Y, Yeh I-H, Liao H-Y M. YOLOv9: Learning What You Want to Learn Using Programmable Gradient Information [J]. arXiv preprint arXiv:240213616, 2024.
- [60]Lin T-Y, Goyal P, Girshick R, et al. Focal loss for dense object detection[C]//Proceedings of the IEEE international conference on computer vision.2017:2980-8.
- [61]Kalman R E. A new approach to linear filtering and prediction problems [J]. 1960.
- [62]Sonka M, Hlavac V, Boyle R. Image processing, analysis and machine vision [M]. Springer, 2013.
- [63]Kuhn H W. The Hungarian method for the assignment problem [J]. Naval research logistics quarterly, 1955, 2(1 - 2): 83-97.
- [64]Bergmann P, Meinhardt T, Leal-Taixe L. Tracking without bells and whistles[C]//Proceedings of the IEEE/CVF international conference on computer vision.2019:941-51.
- [65]Yu F, Wang D, Shelhamer E, et al. Deep layer aggregation[C]//Proceedings of the IEEE

- conference on computer vision and pattern recognition.2018:2403-12.
- [66]Kingma D P, Ba J. Adam: A method for stochastic optimization [J]. arXiv preprint arXiv:1412.6980, 2014.
- [67]Kass M, Witkin A, Terzopoulos D. Snakes: Active contour models [J]. International journal of computer vision, 1988, 1(4): 321-31.
- [68]Chen L-C, Papandreou G, Schroff F, et al. Rethinking atrous convolution for semantic image segmentation [J]. arXiv preprint arXiv:1706.05587, 2017.
- [69]Chen L-C, Zhu Y, Papandreou G, et al. Encoder-decoder with atrous separable convolution for semantic image segmentation[C]//Proceedings of the European conference on computer vision (ECCV).2018:801-18.
- [70]Xingrong Z, Zheng L, Heming Z, et al. Segmentation of right ventricular MR image based on deep neural network: Dilated DenseNet of two level losses[C]//2018 14th IEEE International Conference on Signal Processing (ICSP).IEEE,2018:355-8.
- [71]Zhou X, Zhuo J, Krahenbuhl P. Bottom-up object detection by grouping extreme and center points[C]//Proceedings of the IEEE/CVF conference on computer vision and pattern recognition.2019:850-9.
- [72]Peng S, Jiang W, Pi H, et al. Deep snake for real-time instance segmentation[C]//Proceedings of the IEEE/CVF conference on computer vision and pattern recognition.2020:8533-42.
- [73]Ling H, Gao J, Kar A, et al. Fast interactive object annotation with curve-gen[C]//Proceedings of the IEEE/CVF conference on computer vision and pattern recognition.2019:5257-66.
- [74]Li C, Xu C, Gui C, et al. Distance regularized level set evolution and its application to image segmentation [J]. IEEE transactions on image processing, 2010, 19(12): 3243-54.
- [75]Liu Y, Li C, Guo S, et al. A novel level set method for segmentation of left and right ventricles from cardiac MR images[C]//2014 36th Annual International Conference of the IEEE Engineering in Medicine and Biology Society.IEEE,2014:4719-22.
- [76]Homayounfar N, Ma W-C, Lakshmikanth S K, et al. Hierarchical recurrent attention networks for structured online maps[C]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition.2018:3417-26.
- [77]Liang J, Homayounfar N, Ma W-C, et al. Polytransform: Deep polygon transformer for instance segmentation[C]//Proceedings of the IEEE/CVF conference on computer vision and pattern recognition.2020:9131-40.
- [78]Lee Y, Park J. Centermask: Real-time anchor-free instance segmentation[C]//Proceedings of the IEEE/CVF conference on computer vision and pattern recognition.2020:13906-15.
- [79]Xie E, Sun P, Song X, et al. Polarmask: Single shot instance segmentation with polar representation[C]//Proceedings of the IEEE/CVF conference on computer vision and pattern recognition.2020:12193-202.
- [80]Zhang Y, Wang C, Wang X, et al. Fairmot: On the fairness of detection and re-identification in multiple object tracking [J]. International Journal of Computer Vision, 2021, 129: 3069-87.

- [81]Liang C, Zhang Z, Zhou X, et al. Rethinking the competition between detection and reid in multiobject tracking [J]. IEEE Transactions on Image Processing, 2022, 31: 3182-96.
- [82]Pang J, Qiu L, Li X, et al. Quasi-dense similarity learning for multiple object tracking[C]//Proceedings of the IEEE/CVF conference on computer vision and pattern recognition.2021:164-73.
- [83]Duan K, Bai S, Xie L, et al. Centernet: Keypoint triplets for object detection[C]//Proceedings of the IEEE/CVF international conference on computer vision.2019:6569-78.
- [84]Zheng L, Tang M, Chen Y, et al. Improving multiple object tracking with single object tracking[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition.2021:2453-62.
- [85]涂淑琴, 汤寅杰, 李承桀, et al. 基于改进 ByteTrack 算法的群养生猪行为识别与跟踪技术 [J]. 农业机械学报, 2022, 53(12): 264-72.
- [86]Rezatofighi H, Tsoi N, Gwak J, et al. Generalized intersection over union: A metric and a loss for bounding box regression[C]//Proceedings of the IEEE/CVF conference on computer vision and pattern recognition.2019:658-66.
- [87]Milan A, Leal-Taixé L, Reid I, et al. MOT16: A benchmark for multi-object tracking [J]. arXiv preprint arXiv:160300831, 2016.
- [88]Bernardin K, Stiefelhagen R. Evaluating multiple object tracking performance: the clear mot metrics [J]. EURASIP Journal on Image and Video Processing, 2008, 2008: 1-10.
- [89]Luiten J, Osep A, Dendorfer P, et al. Hota: A higher order metric for evaluating multi-object tracking [J]. International journal of computer vision, 2021, 129: 548-78.
- [90]Lu Z, Rathod V, Votel R, et al. Retinatrack: Online single stage joint detection and tracking[C]//Proceedings of the IEEE/CVF conference on computer vision and pattern recognition.2020:14668-78.
- [91]Aharon N, Orfaig R, Bobrovsky B-Z. BoT-SORT: Robust associations multi-pedestrian tracking [J]. arXiv preprint arXiv:220614651, 2022.

致谢

攻读硕士学位期间研究成果

- [1] 本人第一作者. HFM-Tracker: a cell tracking algorithm based on hybrid feature matching[J]. The Analyst, 2024. (SCI)